实验报告二｜节点成本诊断与多日期验证

从单点影响路径扩展到输出节点诊断和多日期证据

整理日期：2026-10-17。本报告基于既有冻结 CNN 与四种预测头的实际评估记录，不重新训练模型、不改变 Cost 目标或数学约束。

记录项	说明
结果版本	analysis/cnn-cost-attribution；提交 b527981
承接实验	复用实验一完全相同的四种冻结模型、训练 σ 和五档扰动
日期与负荷	27 个预先分层的新日期 + 原参考点，合计 28 个不同日期
正式规模	560 个模型场景、7840 个预测值、8680 次 Cost 评估、17360 个 QP
节点诊断	隔离变化、从完整输出复位单节点；参考点 128 条抽样 Shapley 顺序
测试范围	2019-01-01 至 03-14，仅 seed42、输入节点 1 温度

摘要

实验验证了最大预测变化输出节点与最大 Cost 影响节点是否相同，并比较 TAMU 在不同日期、不同真实负荷水平下的经济性。原始 CNN 的 112 组非零扰动对照中，预测峰值与隔离/复位成本峰值均一致；参考点的抽样 Shapley 检查也一致。隔离影响之和与联合 Cost 变化最大相差 3.246397，说明不能将逐节点隔离影响直接当作严格加性贡献。

27 个新增日期的 108 个非零扰动场景中，TAMU 有 106 个比直接遗忘更便宜；五档分层平均 Cost 均较原始/直接遗忘低。但在 3 月 12 日的−1σ 反例中，TAMU 反而比直接遗忘贵 60.929210，平均优势不构成逐场景保证。

正式实验全部 QP 返回 optimal，最大约束残差 7.38e−8；当时累计 57 项测试通过，完整复算一致。多日期结果仍只覆盖现有前 73 天测试期，不能推出全年、夏季、其他种子或 ERCOT 上的普遍结论。

1 研究问题与分层实验设计

问题一：预测变化最大的输出节点是否也是 Cost 影响幅度最大的节点？问题二：在相同温度扰动和真实负荷下，直接遗忘、重拟合头与 TAMU 的绝对经济性和响应是否改变？问题三：单点发现能否在预先选定的其他日期中观察到？

固定项	设置
模型与温度	实验一四种冻结预测头；input[0,0,0,4]；σ=0.935414141938 编码单位
扰动	−1、−0.5、0、+0.5、+1 训练 σ；仅改变一个输入坐标
控制	每个样本内部固定真实负荷、其他 139 输入、权重和系统约束
月份分层	1 月、2 月、3 月；3 月仅现有测试期的前 14 天
月内负荷分层	按真实总负荷的 1/3、2/3 分位分为低/中/高
每层取样	最接近层内 10%、50%、90%负荷分位的小时，并约束日期不重复
样本数	3 个月 × 3 负荷层 × 3 日期 = 27；另保留参考样本 0，共 28 日期
汇总分母	分层平均与胜出率只用 27 个新日期，参考点不额外加权

选样只使用日期和真实总负荷，不查看任何模型预测或 Cost。选择清单在推理前冻结；1752 个测试时刻的真实总负荷选样池一并保存，能够独立重算选择规则。低/中/高仅是各月内部的相对水平。

数据仍来自官方 TX-123BT 合成测试系统，真实负荷指数据中的 ground truth，而非额外接入的现实电网观测。输入、输出缩放、两阶段费用与约束均继承实验一。

2 输出节点成本诊断方法

记零扰动预测为 f0、完整温度扰动后的预测为 f1，C(f)表示在固定真实负荷下，按原两阶段优化求得的总 Cost。全部 14 个坐标是预测输出节点，不是 14 个温度输入实验。

方法	定义与解释
隔离变化	仅令节点 j 采用 f1[j]，其他输出保持 f0；计算 C(仅 j 变化)−C(f0)
复位诊断	以完整 f1 为背景，仅将 j 复位为 f0[j]；计算 C(f1)−C(仅 j 复位)
抽样 Shapley	按不同顺序逐一加入输出变化，平均每个节点对 C 的边际贡献

隔离与复位诊断对 28 个样本、4 个非零扰动、14 个输出节点执行，生成 1568 行诊断记录，每行包含两种影响。零扰动的 Cost 已在主实验实算，但没有变化的节点无需重复做同值诊断。

参考样本的抽样 Shapley

仅在原始 CNN 参考样本 0 上，对四个非零温度水平进行 Shapley 分摊。使用 64 个独立随机排列及其逆序，共 128 条路径，seed42。相同输出子集的成本缓存复用，但每个新增子集都实际求解原两阶段 QP。

```
贡献_j(π) = C(π 中 j 之前的集合 ∪ {j}) − C(π 中 j 之前的集合)
Shapley_j = 64 个逆序对边际均值的平均
MC 标准误 = 对均值的样本标准差 / sqrt(64)
```

每条路径的边际值望远镜求和等于 C(f1)−C(f0)。守恒仅验证分摊路径一致性，不意味着精确枚举了全部 2^14 个子集。MC 标准误只反映顺序抽样误差，不包含求解误差、日期样本不确定性或模型训练不确定性。

混合输出向量未必对应任何可实现的真实 CNN 输入。这些方法是模型输出的反事实成本诊断，不能直接解释为物理控制因果，也不能把隔离影响之和当成严格的总成本分解。

3 节点诊断的实际结果

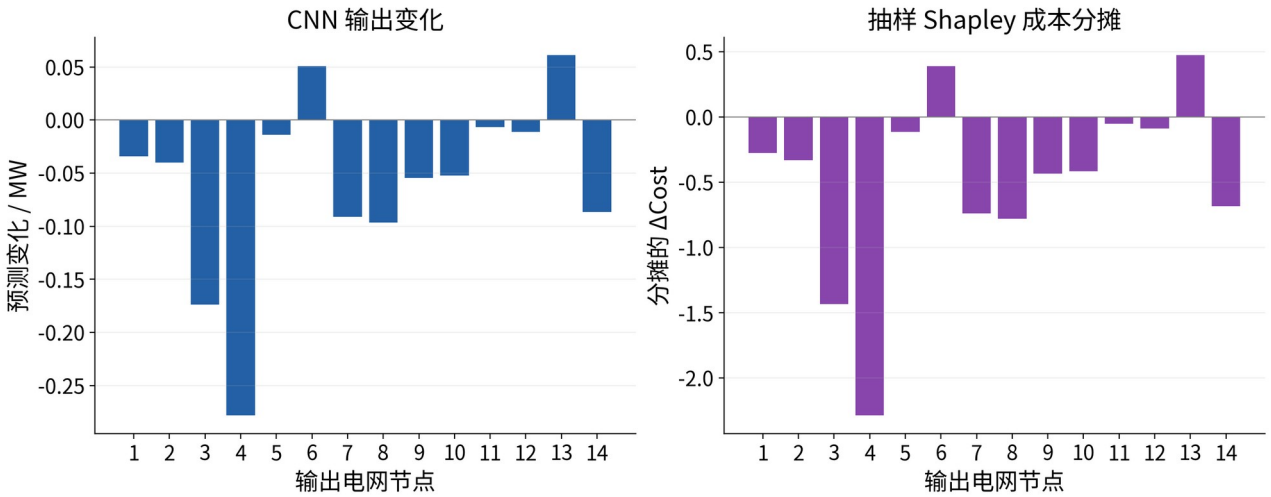


图 1 参考样本+1σ：预测变化与抽样 Shapley 成本分摊

扰动/σ	预测峰值节点	隔离 Cost 峰值	复位 Cost 峰值	Shapley 峰值
-1	3	3	3	3
-0.5	3	3	3	3
+0.5	3	3	3	3
+1	4	4	4	4

在本参考样本中，−1σ、−0.5σ、+0.5σ 的峰值为节点 3，+1σ 的峰值为节点 4。+1σ 下节点 4 预测变化 −0.278248 MW，抽样 Shapley 分配 ΔCost 约−2.289145。这里按绝对幅度排名，符号仍保留。

跨 28 个日期的 112 组非零扰动，预测峰值与隔离/复位峰值均一致（不一致 0 次）。两种诊断的前两名绝对差均大于 1e−4 诊断阈值，但该阈值不是目标值误差的严格上界。不能据本批一致，推出“预测变化最大必然等于成本影响最大”。

隔离影响之和与联合 ΔCost 的最大差为 3.246397。参考点 Shapley 总分配与联合 ΔCost 最大误差 3.55e−15；其 MC 标准误约 1e−9，小于求解误差量级时不应当作有效小数位或总体置信区间。

4 多日期四模型经济性比较

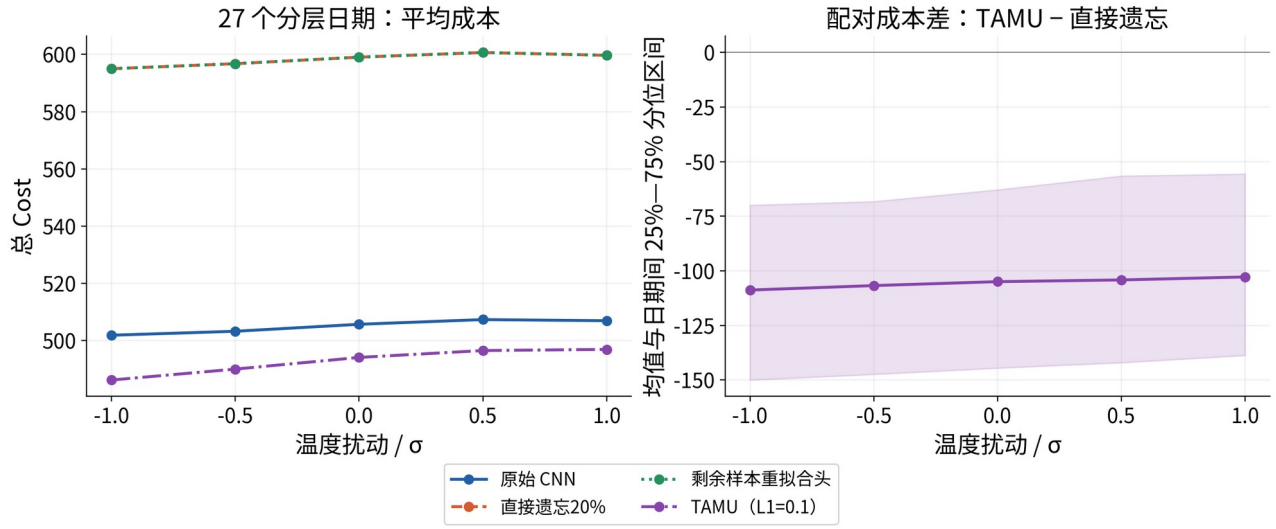


图 2 27 个新日期的平均 Cost 及 TAMU−直接遗忘配对差

σ	原始均 Cost	直接遗忘	重拟合头	TAMU	低于直接	低于原始
-1	501.870	594.992	594.994	486.210	26/27	22/27
-0.5	503.251	596.762	596.764	490.031	26/27	22/27
+0	505.687	599.037	599.039	494.109	26/27	21/27
+0.5	507.337	600.657	600.659	496.516	27/27	20/27
+1	506.936	599.684	599.686	496.912	27/27	21/27

胜出以配对差值<−1e−4 判定。所有模型使用同一批输入、同一真实负荷、相同 Cost 定义。均值在五档上均显示 TAMU 较原始和直接遗忘更便宜；108 个非零场景中，TAMU 相对直接遗忘胜出 106 个，相对原始胜出 85 个。

阴影为所选日期间的 25%—75%分位区间，不是总体置信区间。27 个日期不是随机总体抽样，同一模型下不同日期也可能相关；这些结果是当前固定模型的描述性对照。

5 月份与真实负荷分层结果

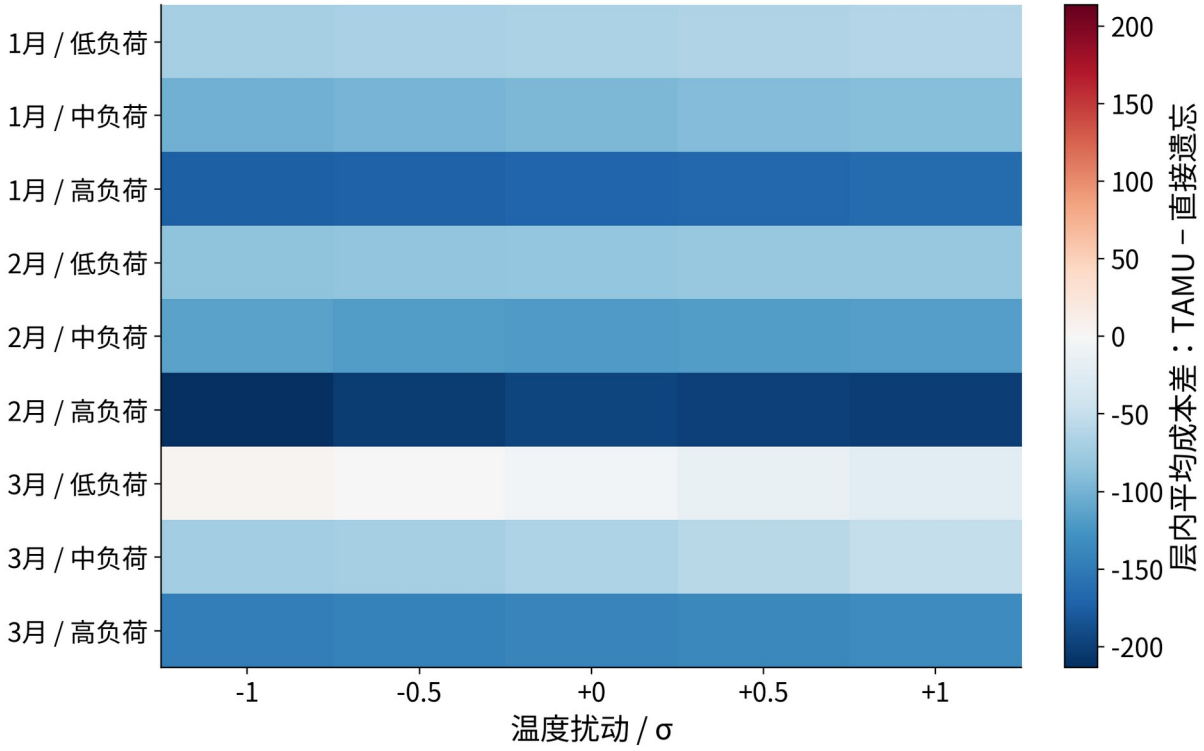


图 3 每层 3 个不同日期；负值表示 TAMU 平均成本低于直接遗忘

该图对 1/2/3 月的低、中、高负荷层分别汇总，避免只展示总体平均值。3 月低负荷层的优势较弱，不能以其他层的较大改善掩盖这一差异。这里的低/中/高仅按对应月份内的真实总负荷划分，不代表全年绝对负荷等级。

日期清单和负荷阈值保存在 selection.json 与 parent_provenance.json；选样池保存在 cohort_inputs.npz。编制报告时没有增删日期，没有根据本轮 Cost 表现替换样本。

参考样本 0 不计入分层平均，防止在 1 月额外加权。绘图和均值均从 paired_model_costs.csv 与 cohort_summary.csv 读取，可与原始逐场景 results.csv 核对。

6 必须保留的反例

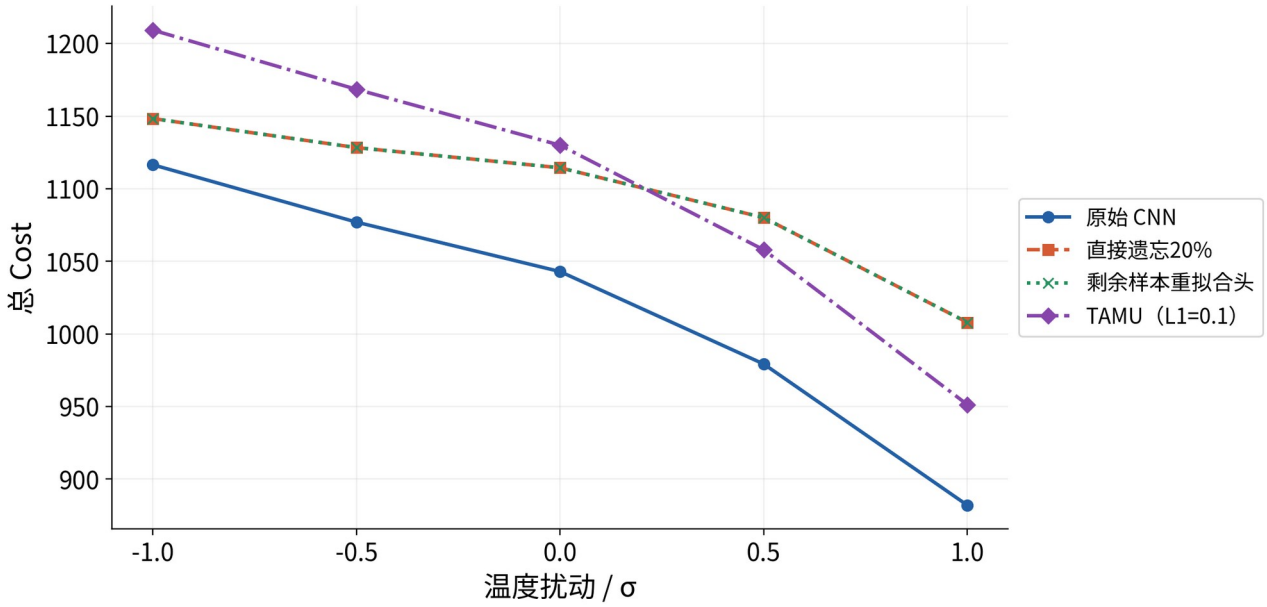


图 4 2019-03-12，源 Hour 7，测试索引 1686，月内低负荷层

模型	cost1	cost2	总 Cost
原始 CNN	156.357328	960.194340	1116.551668
直接遗忘 20%	155.863587	992.506741	1148.370328
剩余样本重拟合头	155.863511	992.512642	1148.376153
TAMU（L1=0.1）	155.001331	1054.298207	1209.299538

在同一真实总负荷 478.328583 MW 下，−1σ 时 TAMU 总 Cost 为 1209.299538，直接遗忘为 1148.370328，前者更贵 60.929210。该日期−0.5σ 和零扰动也存在 TAMU 高于直接遗忘的情况；正向扰动后两者关系发生变化。

这一反例说明：整体平均 Cost 改善不等于每个日期、每个方向都更经济。TAMU 使用原测试平均 Cost 分数恢复权重，没有对本次温度干预场景重新优化，也没有逐场景经济性约束。

7 工程验收与可复现性

验收项	实际记录
固定模型	四种快照与实验一字节相同；干预前后模型哈希不变
样本控制	28 个不同日期；每次固定对应真实负荷；零扰动预测逐位一致、Cost 差 0
正式评估	560 个模型场景、7840 个预测；8680 次 Cost 评估，即 17360 个 QP
节点/子集	1568 行节点诊断；8232 条子集成本记录（含复用主场景端点）
求解状态	全部 optimal，实际使用 GUROBI
约束与费用	最大约束残差 7.38e−8；七项费用分解最大误差 4.55e−13
累计回归测试	57 项通过，0 失败、0 跳过；已包含实验一的 49 项，不能相加为 106 项
独立重放	7840 个预测逐位一致；全部成本 CSV 与求解轨迹逐字节一致
下载包	在无 Git 元数据、无年度数据的解压目录完成 57 项测试及完整重放

复算入口

```
.venv/bin/python experiments/cost_attribution.py \
  --replay-from research/cnn_cost_attribution \
  --output-dir /tmp/cost-path-report-replay
.venv/bin/python experiments/validate_cost_attribution.py \
  --replay-dir /tmp/cost-path-report-replay
```

本次报告制作只读取以上已保存记录，未重新执行实验。逐字节复算一致是原固定环境与相同求解器的验证；换平台或兼容求解器可能出现数值差异。

8 结论、局限与后续工作

本轮结论

- 已建立输入温度→多个输出预测→两阶段 Cost 的可追踪路径，并区分隔离、复位与 Shapley 诊断含义。
- 本批 112 组原始 CNN 对照的峰值节点一致，但逐节点隔离影响不是可直接相加的总成本贡献。
- 所选 27 个日期中 TAMU 平均经济性较好，但存在明确较贵反例；不能将平均优势升级为逐场景或因果保证。

局限

测试期只覆盖 2019 年前 73 天，没有夏季/全年验证；只有 seed42、一个输入节点和温度一个特征。分层样本不是随机总体样本，模型训练和日期间不确定性未被本轮 MC 标准误刻画。混合输出向量也未必是 CNN 可实现输入。

原全年归一化先于划分，helpful/TAMU 使用测试性能信息的协议限制仍然存在。本实验中的 ground truth 属于官方合成测试数据，不代表已经接入 ERCOT 现实观测。

建议下一步（尚未执行）

- 在相同固定模型上扩展其他物理输入特征，先明确各自训练尺度和编码合法性，避免任意破坏 sin/cos 关系。
- 用多个种子与预先确定的场景评估稳定性；把平均 Cost、最差 Cost 和输入敏感性分别报告。
- 如需夏季/全年独立测试，应重新设计时间划分和归一化评估，不能把原训练段直接称为独立测试。
- ERCOT 正式 Cost 实验需先确定节点映射和负荷缩放方案；本轮没有开展该项工作。

源码/数据目录	说明
experiments/cost_attribution.py	冻结推理、反事实、抽样路径及实际 Cost 保存
experiments/validate_cost_attribution.py	样本池重算、全部真实负荷/预测向量、子集费用、重放验收
research/cnn_cost_attribution/	原始结果、完整 8680 次 Cost 轨迹及模型/输入快照
本报告 evidence/与 source_manifest.json	用于文档表格的原数据副本与来源 SHA256

附录 A 参考点+1σ 的逐节点分摊

输出节点	Δ 预测/MW	Shapley cost1	Shapley cost2	Shapley 总计
1	-0.034101	-0.015455	-0.261549	-0.277005
2	-0.040013	-0.024502	-0.306736	-0.331238
3	-0.173673	-0.103445	-1.329494	-1.432939
4	-0.278248	-0.161712	-2.127433	-2.289145
5	-0.014011	-0.007961	-0.107666	-0.115627
6	+0.050643	+0.030603	+0.360423	+0.391026
7	-0.091339	-0.053658	-0.685235	-0.738892
8	-0.096471	-0.056673	-0.723740	-0.780413
9	-0.054381	-0.032126	-0.403863	-0.435989
10	-0.052397	-0.031080	-0.386247	-0.417327
11	-0.006526	-0.003907	-0.047290	-0.051196
12	-0.011382	-0.006866	-0.081286	-0.088152
13	+0.061029	+0.036763	+0.436999	+0.473763
14	-0.086671	-0.051643	-0.633586	-0.685228

表中 Shapley 是 128 条顺序的抽样估计，只适用于原始 CNN 参考点+1σ，不是对全部 28 日期的精确 Shapley 枚举。MC 误差单独保存在 reference_shapley.csv，不能当作求解精度或总体置信区间。

汇总分母说明

统计	分母
原始 CNN 节点峰值比较	28 个日期 × 4 个非零温度水平 = 112 组
TAMU 非零经济性比较	27 个新日期 × 4 个非零水平 = 108 场景；106 场景低于直接遗忘
四模型主场景	28 个日期 × 4 模型 × 5 温度水平 = 560 组
分层平均成本	每个温度水平 27 个新日期；原参考点不计入
回归测试	实验二时累计 57 项；不与实验一 49 项相加