TAMU 算法精读与推导讲义

Newton 遗忘到可微电网优化与样本重加权

task_aware_machine_unlearning 项目学习材料

2026-10-17

导读目录

01 阅读范围与来源边界

02 先修论文与阅读路线

03 符号、形状与被遗忘的对象

04 从经验风险到影响函数

05 算法 A：直接遗忘与剩余集 Newton 更新

06 手算一个删除例子

07 算法 B：性能感知遗忘 PAMU

08 为什么权重优化是 LP，而不是重新求一个非凸网络

09 算法 C：TAMU 为什么要把电网优化接进来

10 项目两阶段电网模型的数学表达

11 “三层优化”应该怎样理解

12 从 KKT 推导优化层的梯度

13 梯度存在需要什么条件

14 两阶段 Cost 的完整链式法则

15 三类方法的伪代码与不同保证

16 不显式求逆：iHVP、CG 与阻尼

17 与当前仓库的逐项对应

18 连接到你的“温度—预测—Cost”实验

19 读懂之后必须能够辨认的边界

20 建议怎样核验每一条计算链

21 给导师讲解时可以使用的一段话

22 附录：实际来源、复现与待补核验

阅读范围与来源边界

目标论文：Wangkun Xu、Fei Teng，*Task-Aware Machine Unlearning and Its Application in Load Forecasting*，IEEE Transactions on Power Systems，2024。DOI：10.1109/TPWRS.2024.3376828。用户指定入口：arXiv 2308.14412；摘要页；PDF。X

必须先说明的核验限制：本次环境访问 arXiv、IEEE、PMLR 等论文站点时，网络代理返回 403。已实际读取作者原仓库的论文摘要、算法实现，影响函数、OptNet、CVXPYLayers、task-based learning、certified removal 配套仓库，以及作者的可微凸优化讲义；**没有取得目标论文及铺垫论文的完整正文**。因此，本讲义是“作者代码核对 + 标准数学知识的独立推导”，不是已经逐页核对原文的正式精读定稿。以下 G 编号、算法 A/B/C、图及例子均为本讲义自编，不能当作原论文的公式、算法、定理编号。

本讲义可以帮助理解已核验代码所实现的方法；目标论文各版本的完整假设、证明细节和引用关系，仍需在取得 PDF 后逐项对照。文末书单是**理解方法的推荐先修文献**，并不声称它们全部出现在目标论文参考文献中。链接已经写入同一 Word，可以点击；被代理拦截的论文正文链接未完成在线有效性核验。

本材料不重新训练模型、不生成新的论文实验结果、不修改 Cost 数学模型。标注“教学例子”的数值来自随附脚本的独立计算；标注“项目既有实验”的数值来自已保存实验 CSV。二者分开解释。

先抓住三个问题

直接遗忘：删去一部分训练样本后，如何不从头拟合而得到接近剩余数据重训的参数?

性能感知遗忘 PAMU：删除样本会损伤 MSE/MAPE，能否通过调整剩余样本的重要性补偿?

任务感知遗忘 TAMU：预测误差不等于电网经济损失，能否用真正的调度成本指导这种补偿?

其中第一个问题需要“影响函数 / Newton 法”；第二个增加“外层性能梯度与样本权重”；第三个再增加“可微调度优化与链式求导”。论文方法的思想递进可由这三层理解。



先修：影响函数 P1 → KKT / OptNet P2 → CVXPYLayers P3 → 任务损失 P4

方法依赖图

先修论文与阅读路线

最短阅读顺序

先读 P1 的影响函数定义与参数扰动推导，再结合本讲义 G1—G8 手算一次删除；补 K1 的 KKT 与 Newton 知识；读 P2 的 QP 隐式求导和 P3 的可微凸优化层；最后读 P4 的任务损失思想，返回 TAMU 的样本评分和权重 LP。P5 帮助理解“参数更新接近重训”和“隐私认证”之间的区别。

层次	文献	解决的理解障碍	在本讲义的位置
核心	P1 Koh & Liang，2017	为什么改变一个样本权重会产生 $-H^{-1}g_i$?	影响函数、评分正负号
核心	P2 Amos & Kolter，2017，OptNet	优化器为什么可以作为神经网络的一层?	KKT 导数、伴随方程
核心	P3 Agrawal 等，2019，CVXPYLayers	CVXPY 问题如何成为可微层？DPP 是什么?	Cost 反向传播、实现
核心	P4 Donti、Amos、Kolter，2017	为什么低 MSE 不保证低运行成本?	TAMU 外层目标
边界	P5 Guo 等，2020	什么才是有认证的数据删除？Newton 更新有哪些条件?	遗忘保证的边界
数学	K1 Boyd & Vandenberghe，2004	凸性、对偶、KKT、Newton 法	全文推导基础

铺垫论文链接及具体读法

P1．Understanding Black-box Predictions via Influence Functions。Pang Wei Koh、Percy Liang，ICML 2017。论文：PMLR 页面；arXiv 1703.04730。作者代码。已读取作者代码 README，标题、作者、会议与方法介绍可核对；正文未取得。X

重点学习：经验风险极小点的驻点条件；单样本 upweight 的导数；测试损失的影响分数；如何避免显式构造逆 Hessian。读完应能够解释“增权”和“删除”为何符号相反。TAMU 继承的是这种局部敏感性工具，不是直接套用黑箱重要性排序。

P2．OptNet: Differentiable Optimization as a Layer in Neural Networks。Brandon Amos、J. Zico Kolter，ICML 2017。论文：PMLR 页面；arXiv 1703.00443。作者代码。已读取作者代码 README，书目信息及 QP 层思想可核对；正文未取得。

重点学习：带参数 QP 的原始—对偶变量；对 KKT 方程全微分；反向传播时求解转置线性系统。读完应能够解释“求解最优点”和“求最优点对输入的导数”是两次不同操作。

P3．Differentiable Convex Optimization Layers。Akshay Agrawal、Brandon Amos、Shane Barratt、Stephen Boyd、Steven Diamond、J. Zico Kolter，NeurIPS 2019。论文：arXiv 1910.12430；作者 PDF。配套库。已读取库 README 和 BibTeX，题名与作者可核对；正文未取得。

重点学习：参数化凸问题、锥规划表示、规范化与恢复映射、DPP 的作用。项目使用 CVXPYLayers，不应把“Gurobi 可以解出一个数值最优解”当作“该数值求解调用自动具有 PyTorch 梯度”。

P4．Task-based End-to-end Model Learning in Stochastic Optimization。Priya L. Donti、Brandon Amos、J. Zico Kolter，NeurIPS 2017。论文：arXiv 1703.04529。作者代码。已读取作者 README，确认研究目的、书目信息和电网调度应用说明；正文未取得。

重点学习：预测误差与下游任务损失的区别；把预测送进决策模型，再按决策结果评价模型。TAMU 将这种任务损失思想用于删除数据之后的剩余样本重加权，而当前仓库的基础训练损失仍为 MSE。

P5．Certified Data Removal from Machine Learning Models。Chuan Guo、Tom Goldstein、Awni Hannun、Laurens van der Maaten，ICML 2020。论文：arXiv 1911.03030。作者代码。已读取作者 README，确认 Newton 更新、梯度残差与认证删除的关系；正文未取得。

重点学习：删除后模型与重训模型的比较对象；梯度残差控制；噪声与认证保证所需额外条件。不能把本项目里“预测头参数差很小”直接升级为满足认证删除定义。

K1．Convex Optimization。Stephen Boyd、Lieven Vandenberghe，2004。这是教材，不是论文。免费入口：教材主页；PDF。建议阅读第 5 章的对偶与 KKT，第 9—10 章的 Newton / 等式约束最小化。链接未在当前代理环境下成功打开。

K2．Fast Exact Multiplication by the Hessian。Barak A. Pearlmutter，Neural Computation，1994。论文：DOI 10.1162/neco.1994.6.1.147。用于理解 Hessian-vector product；可在掌握主要推导后补读，不必先实现完整 Hessian。正文未取得。

扩展阅读：有明确用途再读

编号	文献及链接	适用问题
E1	Giordano 等，*A Swiss Army Infinitesimal Jackknife*，AISTATS 2019：arXiv 1806.00550	理解用局部权重扰动近似重拟合，以及近似误差为何需要假设

编号	文献及链接	适用问题
E2	Bourtoule 等，*Machine Unlearning*，IEEE S&P 2021：arXiv 1912.03817	对照 SISA 这类预先设计训练过程的遗忘方法
E3	Elmachtoub、Grigas，*Smart "Predict, then Optimize"*，Management Science 2022：arXiv 1710.08005	扩展理解决策导向预测；不是本仓库已实现的损失函数
E4	*A Synthetic Texas Backbone Power System with Climate-Dependent Spatio-Temporal Correlated Profiles*：arXiv 2302.13231；官方数据页	理解实验数据是合成测试系统的数据，而非 ERCOT 实地观测
E5	Tolstikhin 等，*MLP-Mixer: An all-MLP Architecture for Vision*，2021：arXiv 2105.01601	仅当需要理解项目另一个特征提取器时阅读

E1—E5 以推荐背景材料列出，未在本次环境中取得正文；E4、E5 的链接也出现在原项目 README。它们不是理解 CNN + TAMU 主线的必读前置条件。

符号、形状与被遗忘的对象

符号	含义	当前 CNN 实验中的对应
D、U、R	原拟合集、删除集、剩余集，$D = U \cup R$	CNN 的敏感集，而非全部 core + sensitive 数据
n, k, m	上述集合大小，$n = k + m$	4906、981、3925
x	一条原始编码输入	$1 \times 14 \times 10$，140 个输入值
$h_\phi(x)$	冻结特征提取器	CNN 输出的 64 维 tanh 隐表示
f_θ	可更新预测器	$W h_\phi(x) + b$，输出 14 维
θ	被拟合/遗忘的参数向量	$14 \times 64 + 14 = 910$ 个头部参数
$\ell_i(\theta)$	第 i 个训练样本的 MSE	对该样本 14 个节点误差求平均
L_S、H_S	集合 S 的平均训练损失及 Hessian	不是 Cost 的 Hessian
J	外层评估损失	MSE、MAPE 或两阶段 Cost 的平均
w_i	剩余训练样本的完整权重	以 1 为基准，当前约束下为 $[0, 2)$

三个容易混淆的量：$\nabla_\theta J$ 是改变参数对外层指标的影响；$\partial J / \partial w_i$ 是改变训练样本重要性的影响；$\partial J / \partial x_j$ 是固定模型时改变输入特征的影响。它们通过链式法则相连，但含义不同。

网络核心在 core 数据上训练，再冻结核心，在 sensitive 数据的隐藏特征上拟合仿射头。因而本文所讲"一步精确删除"指满足条件的二次预测头，不是整个非凸 CNN 的任意层都可以一步精确遗忘。若删除对象也参与过核心训练，仅更新预测头不足以移除它对核心的影响。

从经验风险到影响函数

G1：模型为什么停在某个参数上

将训练目标写成

$$L_D(\theta)=\frac{1}{n}\sum_{i\in D}\ell_i(\theta),\theta_0=\underset{\theta}{argmin}\,L_D(\theta).$$

在可微且取得内点极小解的情形，$\nabla_\theta L_D(\theta_0)=0$。定义 $H_D=\nabla_\theta^2 L_D(\theta_0)$。它描述参数变化时，训练梯度改变的速度。严格正定是后面求逆/CG 的一种充分条件；原项目对冻结仿射头的 MSE 有二次结构，但是否满秩仍应检查。

G2：把一个样本稍微增权

采用 P1 常用的“额外添加 $\epsilon\,\ell_i$”约定：

$$L_{\epsilon,i}(\theta)=L_D(\theta)+\epsilon\,\ell_i(\theta),\nabla_\theta L_{\epsilon,i}(\theta_{\epsilon,i})=0.$$

对 ϵ 全微分，在 $\epsilon=0$ 处记 $g_i=\nabla_\theta\ell_i(\theta_0)$，得到

$$H_D\frac{d\theta_{\epsilon,i}}{d\epsilon}\Big)_0+g_i=0,\frac{d\theta_{\epsilon,i}}{d\epsilon}\Big)_0=-H_D^{-1}g_i.$$

这一步使用的是隐函数定理：权重改变后，新的参数必须继续满足“训练梯度为零”，所以参数要沿抵消新增梯度的方向移动。负号来自把 g_i 移到方程右边。

G3：把参数影响转成指标影响

令 $v=\nabla_\theta J(\theta_0)$。若 J 不直接依赖样本权重，则

$$\frac{dJ(\theta_{\epsilon,i})}{d\epsilon}\Big)_0=-v^TH_D^{-1}g_i.$$

g_i 指出该训练样本试图推动的方向，H_D^{-1} 用训练损失的曲率校正方向，v 衡量该方向会让外层指标上升还是下降。相似的预测误差并不保证相似的影响分数。

G4：删除为什么翻转符号，为什么有 $1/n$

删除单样本，可先从全数据平均目标中减去 ℓ_i/n。无正则化时，剩余目标整体乘以正数不会改变最优点，因此采用 $\epsilon=-1/n$ 可得局部近似

$$\Delta\theta_i\approx\frac{1}{n}H_D^{-1}g_i,\Delta J_i\approx\frac{1}{n}v^TH_D^{-1}g_i.$$

这里从“无穷小增权导数”代入一个有限删除量，通常只是近似。删除比例较大时误差可能增加；若目标含固定强度的正则项，还必须明确删除后正则化如何归一化，不能直接照搬这个整体缩放论证。当前头部训练的正则项为零。

如果改用“完整权重 w_i，目标为 $\sum_i w_i \ell_i / n$”的约定，则 $\partial\theta / \partial w_i = -H_D^{-1} g_i / n$。两种公式一致，差别只是扰动参数的定义。

算法 A：直接遗忘与剩余集 Newton 更新

G5：对剩余目标做一次 Newton

直接求剩余集重训解 $\theta_R = arg\,min\, L_R(\theta)$ 可能昂贵。在旧参数处计算

$$g_R = \nabla L_R(\theta_0), H_R = \nabla^2 L_R(\theta_0), \theta_{del} = \theta_0 - H_R^{-1} g_R.$$

这是当前 eval_unlearn.py 所实现的关键更新。stest 只是“计算梯度 + 求逆 Hessian 向量积”的封装。这里的 train_loader 和 test_loader 都传入剩余数据，名字中出现 test 不表示此处真的使用了留出测试集。

G6：为什么冻结仿射头可以精确到数值误差

把每条隐藏特征增广为 $\tilde{h}_i = [h_i; 1]$，把所有输出参数适当展平，得到线性设计矩阵 X 和目标向量 Y。MSE 的正数归一化系数不影响最小点。用等价的半平方误差写法：

$$L_R(\theta) = \frac{1}{2m} \| X_R\theta - Y_R \|^2, H_R = \frac{1}{m} X_R^T X_R, g_R = H_R\theta_0 - \frac{1}{m} X_R^T Y_R.$$

当 $X_R^T X_R$ 可逆时，代入 G5：

$$\theta_{del} = \theta_0 - H_R^{-1}\left(H_R\theta_0 - \frac{1}{m} X_R^T Y_R\right) = \left(X_R^T X_R\right)^{-1} X_R^T Y_R = \theta_R.$$

精确性来自“二次目标的梯度是仿射函数”。它甚至不要求 Newton 的起点刚好是全数据最优点；但要求用正确的剩余集 Hessian，线性系统求解足够准确。秩亏、阻尼、数值精度、CG 截断都会影响结果。

G7：同一个删除更新的另一种写法

若原始参数满足 $\sum_{i \in D} g_i = 0$，则

$$m\, g_R = \sum_{i \in R} g_i = -\sum_{i \in U} g_i = -k\, g_U,$$

从而

$$\theta_{del}=\theta_0+\frac{k}{m}H_R^{-1}g_U.$$

这解释了为什么某些删除代码使用“加号”，另一些使用“减号”：它们分别使用删除集梯度和剩余集梯度。必须同时核对 Hessian 的数据集合、梯度的平均方式及 k/m 系数。

G8：旧 Hessian 与剩余 Hessian 不是一回事

$$H_D=\frac{m}{n}H_R+\frac{k}{n}H_U.$$

即使目标是二次函数，拿 H_D 代替 H_R 也一般失去一次更新等于剩余集重训的性质。P1 的局部删除近似与项目的剩余 Hessian Newton 更新有共同思想，但不是可以不加区分地互换的公式。

算法 A 的实现顺序：固定核心并准备剩余特征；在 θ_0 计算 g_R；求解 $H_R\Delta=g_R$；令 $\theta=\theta_0-\Delta$；检查残差并与剩余集拟合解比较。无需显式计算整个逆矩阵。

手算一个删除例子

教学例子，不是 TX-123BT 实验。 单参数模型 $f_\theta(x)=\theta x$，数据 $(1,1),(2,2),(3,0)$，损失为半平方误差。删除第三条，保留前两条。

全数据解为 $\theta_0=(1+4)/(1+4+9)=5/14$。剩余集直接拟合得到 $\theta_R=1$。在 θ_0 处有

$$H_R=\frac{1^2+2^2}{2}=\frac{5}{2},g_R=\frac{(\theta_0-1)+2(2\theta_0-2)}{2}=-\frac{45}{28}.$$

因此 $\theta_0-g_R/H_R=1$。若错误地把同一步中的 H_R 换成 $H_D=14/3$，结果是 $275/392\approx0.701531$，不等于 1。

若采用 G4 的“单样本无穷小删除近似”，它的结果约为 0.586735；这和“直接替换 Hessian”的 0.701531 又不同，因为 G4 使用的是单样本删除扰动量，G5 使用的是归一化后的剩余梯度。比较公式时不能只看正负号。

随附 verify_derivations.py 会独立计算这三种结果，并对正确 Newton 更新与直接拟合的一致性进行断言。

算法 B：性能感知遗忘 PAMU

G9：给剩余样本完整权重

令删除集不进入最终拟合，剩余目标为

$$L_R(\theta;w)=\frac{1}{m}\sum_{i\in R} w_i \ell_i(\theta), \theta(w)=arg\min_{\theta} L_R(\theta;w).$$

理想目标是，在有限权重调整预算内最小化 $J(\theta(w))$。如果 J 是评估集 MSE/MAPE，就是性能感知方法；如果 J 是运行成本，就进入 TAMU。权重用于训练样本，不是神经网络连接权重，也不是改变电网负荷场景的概率。

G10：理想权重导数

在 $w=1$ 时，真正的内层解是 θ_R。若 Hessian 在该点可逆，隐式求导给出

$$\left.\frac{\partial\theta(w)}{\partial w_i}\right|_1 = -\frac{1}{m} H_R(\theta_R)^{-1} g_i(\theta_R),$$

$$s_i^{ideal}=\left.\frac{\partial J(\theta(w))}{\partial w_i}\right|_1 = -\frac{1}{m}\nabla J(\theta_R)^T H_R(\theta_R)^{-1} g_i(\theta_R).$$

这是一条严格的局部导数公式，有明确锚点 θ_R；它说明有利/不利的训练样本会因外层评价标准改变而改变。

G11：当前代码实际算的分数

eval_unchange.py 为减少计算、复用原模型，在 θ_0 而非 θ_R 计算各样本梯度与外层梯度，并用剩余集 Hessian：

$$v_0=\nabla J(\theta_0), M=-H_R(\theta_0)^{-1}v_0, s_i^{code}=\frac{1}{n} g_i(\theta_0)^T M.$$

因此不能声称 G11 是 G10 在代码中逐项精确实现：锚点及归一化不同。$1/n$ 相对 $1/m$ 是共同正比例因子，单独用于当前线性目标时不会改变权重 LP 的最优解集合；但若把分数和直接数值 ΔJ 比较，必须恢复正确比例。锚点变化本身则是额外的局部近似。

二次目标下 H_R 不随 θ 变化，但 g_i 和 ∇J 仍会变，不能因为 Hessian 恒定就忽略锚点区别。

G12：由局部近似得到权重问题

在选定锚点附近，写成

$$J(\theta(w))\approx 常数+\sum_{i\in R} s_i(w_i-1).$$

省略与 w 无关的项，得到代码实际求解的代理目标

$$\min_{w}\sum_{i\in R} s_i w_i \text{ s.t. } \|w-1\|_1\le c\,m, \|w-1\|_\infty\le 1.$$

当 $s_i>0$ 时，局部代理倾向降低该样本的权重；当 $s_i<0$ 时，倾向提高权重。这里 s_i 表示**增权**影响，不能把它直接称为删除影响。

约束意味着 $0\le w_i\le 2$，平均绝对权重偏离不超过 c。L1=0.1 是平均偏离预算；它不是“删去 10% 数据”，也不是参数 L1 正则化。当前 $m=3925$，总偏离预算是 392.5。

为什么权重优化是 LP，而不是重新求一个非凸网络

令 $t_i\ge 0$，将绝对值约束等价写成

$$-t_i\le w_i-1\le t_i,\sum_i t_i\le c\,m,0\le w_i\le 2.$$

目标线性，约束全为线性，故是线性规划。ECOS 的等价锥表示与 GUROBI 的线性表示可以求解同一个问题；更换兼容求解器不需要改变目标或增加数学约束。

当前 LP **没有** $\sum_i w_i=m$ 的守恒约束。自行增加这一约束会改变问题。由于训练项全为 MSE 且没有正则化，所有权重整体乘同一个正数不会改变拟合极小点，但会影响代码的权重预算与线性代理值，不能以此随意重新归一化最优权重。

教学例子：三个样本的分数为 $(2,-1,0.5)$，预算 $c\,m=1$。原权重 $(1,1,1)$ 的代理目标为 1.5；可行权重 $(0,1,1)$ 的代理目标为 -0.5，是这个例子的最优解。预算优先花在将第一个高正分数样本减权，而不是把所有剩余样本同样缩小。

权重 LP 只保证“该固定局部线性代理最优”，并不保证最终真实 Cost 全局最小，更不保证所有新样本都降低 Cost。$w=1$ 总是可行，故最优代理不差于不重加权的代理；这个结论不能自动搬到未经线性化的真实评估指标上。

G13：得到权重后如何产生新参数

固定最优权重 w^*，代码重新构造加权 MSE 的 Hessian 与梯度：

$$H_{R,w}=\nabla^2 L_R\left(\theta_0;w^*\right),g_{R,w}=\nabla L_R\left(\theta_0;w^*\right),\theta_{PAMU}=\theta_0-H_{R,w}^{-1}g_{R,w}.$$

若加权设计矩阵保持满秩，MSE 仍为二次函数，G13 等于该**加权剩余集**的精确拟合解。它一般不等于无权重剩余集重训解 θ_R。前者的精确性不表示后者的相同，也不表示全部隐私要求自动成立。

有些权重可达到 0；加权系统可能因此秩亏，正权重的个数也不是满秩的充分条件。应核对 Hessian 条件数、线性系统残差和求解状态，不能仅检查最终预测“看上去合理”。

算法 C：TAMU 为什么要把电网优化接进来

P4 的关键启发是：预测误差应通过它造成的决策后果来评价。负荷低估可能造成失负荷费用，高估可能造成过量发电处理费用；线路与机组约束还会让相同误差在不同节点产生不同成本。

教学例子，与原论文模型分开：一个节点真实负荷为 1，预测分别是 0.9 和 1.1，二者平方误差均为 0.01。为直观说明非对称性，暂用无网络、无线性外其他费用的简化成本

$$C(q)=q+100(1-q)_+ +10(q-1)_+.$$

则 $C(0.9)=10.9$，$C(1.1)=2.1$。该简例不替换项目两阶段问题，只解释为何“同样 MSE”可以有很不同的经济性。$q<1$ 时导数为 -99，$q>1$ 时导数为 11；在 $q=1$ 存在折点。

TAMU 与 PAMU 的主要区别是把外层 J 换成实际两阶段 Cost，使 $v=\nabla_\theta J$ 通过优化层得到。训练 Hessian 仍然取自 **MSE**，没有换成 Cost Hessian。



温度扰动实验改变输入 x；TAMU 改变训练样本权重 w。二者通过同一预测–优化路径连接。

输入、预测、调度和反向梯度路径

项目两阶段电网模型的数学表达

以下完整写出**当前已修复仓库实际使用的数学问题**，不是未核验原文的逐字转录。设预测负荷为 $\hat{d}$，真实负荷为 d，发电为 p，削减负荷为 s，过量发电处理变量为 g，相角为 α。所有功率以 p.u. 进入优化，MW 展示需乘 baseMVA。

G14：阶段一，依据预测做调度

最小化下式 C_1，决策变量为 p, s_1, α_1：

$$C_1=p^T\,diag(a)\,p+b^T p+\lambda 1^T s_1.$$

分别满足发电限额、线路限额、节点功率平衡和参考角约束：

$$0 \le p \le \acute{p}, -\acute{f} \le B_f \alpha_1 \le \acute{f}.$$

$B_{bus}\alpha_1 = C_g p - C_l\left(\hat{d} - s_1\right).$

$s_1 \ge 0, \alpha_{1,ref} = 0.$

C_g, C_l 分别把机组出力和负荷映射到节点。B_{bus} 是直流节点功率关系矩阵，B_f 将相角转为支路潮流。阶段一输出不仅有 p^*，还有 s_1^*；Cost 及其梯度必须包含阶段一削减费用。

G15：阶段二，以相同真实负荷评价偏差

最小化下式 C_2，决策变量为 s_2, g, α_2：

$$C_2 = \lambda 1^T s_2 + \kappa \parallel s_2 \parallel^2 + \rho 1^T g + \eta \parallel g \parallel^2.$$

固定阶段一传来的 p^*，分别满足：

$$-\acute{f} \le B_f \alpha_2 \le \acute{f}.$$

$B_{bus}\alpha_2 = C_g\left(p^* - g\right) - C_l\left(d - s_2\right).$

$s_2 \ge 0, g \ge 0, \alpha_{2,ref} = 0.$

总成本为 $C\left(\hat{d}, d\right) = C_1\left(p^*, s_1^*\right) + C_2\left(s_2^*, g^*\right)$。当前系数是 $\lambda = 3500, \kappa = 1250, \rho = 700, \eta = 250$；$a, b$ 来自 case 修改器。沿用仓库目标函数单位，不转换成未经校准的实际市场价格。

当前阶段二通过 $p^* - g$ 允许处理过量发电，模型没有另外给自由增加发电的变量；短缺由 s_2 处理。仓库也没有 $s_1 \le \hat{d}$、$s_2 \le d$、$g \le p^*$ 这些上界，不能在“解释原模型”时自行添加它们。它们如需改进应单独研究。

G16：输入和单位链

$\hat{d} = ReLU\left(\sigma_y \odot f_\theta\left(h_\phi(x)\right) + \mu_y\right).$

f_θ 输出标准化目标，反标准化后为 p.u. 负荷，负预测沿用原逻辑截为 0。误把标准化值直接送进调度、或又乘/除一次 baseMVA，都会改变问题。反向传播也必须经过反标准化和非负截断；截断边界会引入不光滑点。

“三层优化”应该怎样理解

对一个评估样本，固定参数时有以下嵌套关系：外层选择剩余样本权重，内部用预测负荷解阶段一，再用真实负荷和阶段一发电解阶段二。若将权重到参数的映射单独展开，还会看见一个加权训练子问题。层数名称不能代替把每个变量的依赖写清楚。

用 $z_1^*(\hat{d})$ 表示阶段一最优变量，$z_2^*(p^*, d)$ 表示阶段二最优变量，记 P 为从 z_1 取出机组发电的选择矩阵。完整依赖是

$$w \to \theta(w) \to \hat{d} \to z_1^*(\hat{d}) \to z_2^*(P z_1^*, d) \to C.$$

外层的经验目标可写为

$$J_C(\theta(w)) = \frac{1}{N_v} \sum_{t=1}^{N_v} C\left(\hat{d}_\theta(x_t), d_t\right).$$

理想问题是直接在权重约束中最小化这个嵌套的真实成本；代码采用局部影响分数和 LP 作为可计算近似，再对所得加权头做真实 Cost 评估。它不是穷举权重，也不是对这个完整嵌套问题给出全局最优保证。

从 KKT 推导优化层的梯度

G17：把一个 QP 的最优点变成隐函数

考虑参数为 u 的一般凸 QP：

$$\min_z \frac{1}{2} z^T Q z + q(u)^T z \; s.t. \; A z = b(u), G z \le h(u).$$

此处为突出推导，先假设 Q, A, G 固定。令 v 为等式乘子，β 为不等式乘子。最优点满足 KKT：

$$Q z + q + A^T v + G^T \beta = 0, \; A z - b = 0,$$

$$G z - h \le 0, \; \beta \ge 0, \; \beta \odot (G z - h) = 0.$$

前两式来自驻点与可行性，最后一式是互补松弛：不活跃约束的乘子为 0，具有正乘子的约束必须紧。

G18：在活跃集合不变的局部区域求导

令活跃约束索引为 A。将它们与等式约束一起视作局部等式，对 KKT 全微分：

$$\begin{bmatrix} Q & A^T & G_A^T \\ A & 0 & 0 \\ G_A & 0 & 0 \end{bmatrix} \begin{bmatrix} dz/du \\ dv/du \\ d\beta_A/du \end{bmatrix} = \begin{bmatrix} -dq/du \\ db/du \\ dh_A/du \end{bmatrix}.$$

左侧为 KKT 线性系统。若该矩阵可逆，就能解出 dz^*/du。若 Q, A, G 也依赖 u，右侧还必须加入例如 $-(dQ/du)z$、$-(dA^T/du)v$ 等项，不能丢掉。

这就是 P2 的核心计算思想：前向求最优点，反向对最优性条件求导。CVXPYLayers 使用更一般的凸问题规范化与锥规划求导机制，概念上与此相通，并不要求用户手写每个 KKT 矩阵。

G19：为什么反向用伴随方程

将最优性条件简写为 $F(y,u)=0$，y 包含原始—对偶变量。令 $K=F_y$，$B=F_u$。于是

$$\frac{dy}{du}=-K^{-1}B.$$

对标量目标 $C(y,u)$，按列梯度约定有

$$\nabla_u C=C_u-B^T K^{-T}C_y.$$

先求解 $K^T a=C_y$，再计算 $\nabla_u C=C_u-B^T a$，无需构造整个 K^{-1} 或完整 Jacobian。注意这是**伴随**向量 a，不是发电二次系数表中也曾用过的系数；上下文不同。

梯度存在需要什么条件

KKT 驻点条件能写出来，不等于每一点的解映射都可微。一个便于理解的局部充分条件组合是：活跃约束梯度线性无关、严格互补，以及约束切空间上的二阶充分条件，使局部 KKT 系统非奇异、活跃结构稳定。更一般理论有不同表述，不能把此组合冒充目标论文定理的原始假设。

需要区分：

目标/约束是凸的：有利于求全局最优点，但不保证最优点唯一。

目标是严格凸的：有助于唯一性，但仍不保证跨活跃集边界处处可微。

局部 KKT 系统非奇异：允许在该局部通过隐函数定理求导。

DPP 合规：使参数化规范化具有规定结构，适合可微层；不是处处可微的独立充分证明。

当前调度目标并非对全部相角、削减变量都严格凸，不能仅因发电有二次项就断言整个决策向量处处唯一。参考相角消除一类自由度，也不自动消除所有退化。线路约束活跃集切换、多个最优解、非负截断为 0 的边界，都可能造成不光滑或数值导数不稳定。

因此，“代码可以反向传播”“有限差分在某点吻合”“某些条件下理论梯度存在”是不同层次的证据。本文没有取得目标论文原定理，不能替它补写一个未经核对的全局可微性证明。

两阶段 Cost 的完整链式法则

G20：不能只对阶段一最优值求导

设 $A_1=\partial z_1^*/\partial \hat{d}$，$A_2=\partial z_2^*/\partial p^*$。将成本看成 $C(z_1,z_2)$，固定真实负荷 d，有

$$\nabla_{\hat{d}} C = A_1^T\left[\nabla_{z_1} C + P^T A_2^T \nabla_{z_2} C\right].$$

其中第一项是阶段一最优变量改变其自身费用，第二项是阶段一发电改变阶段二最优决策及费用。仅使用阶段一最优值的包络导数，不能完整覆盖第二条路径。若模型另外有对 $\hat{d}$ 的显式费用，还需加入该偏导；当前费用表达没有这一项。

G21：从预测梯度到参数梯度

令 $F_\theta=\partial \hat{d}/\partial\theta$，则

$$v_C=\nabla_\theta J_C=\frac{1}{N_v}\sum_t F_{\theta,t}^T \nabla_{\hat{d}_t} C.$$

SPO 封装中，标准化预测经过反标准化、ReLU、阶段一层和阶段二层；MSE_COST.test_loss 重新组合所有费用项，使自动微分得到 v_C。

G22：从参数梯度到每条训练样本分数

沿用 G11 的代码约定：

$$s_i^C=-\frac{1}{n} g_i(\theta_0)^T H_R^{-1} v_C.$$

只需解一次 $H_R a=v_C$，随后对每个训练样本做内积 $s_i^C=-g_i^T a/n$。不需要针对每个训练样本重新跑一遍完整两阶段反向图。

再将 s_i^C 送入同一个权重 LP，得到 w^*，最后通过 G13 拟合加权剩余集预测头。这就是当前可核验 TAMU 计算链。

三类方法的伪代码与不同保证

算法 A：直接遗忘

输入：冻结的核心、原始预测头 theta0、删除集 U、剩余集 R

g = grad_theta MSE_R(theta0)

H = Hessian_theta MSE_R(theta0)

解 H delta = g

theta_del = theta0 - delta

验证线性系统残差；与剩余集头部重拟合比较

算法 B：PAMU

输入：算法 A 的数据；外层标准 J = MSE 或 MAPE

在 theta0 计算 v = grad_theta J（评估数据）

在 theta0 计算 H_R（剩余训练数据的 MSE Hessian）

解 H_R a = v

逐样本计算 g_i，s_i = -dot(g_i, a) / n

在 L1 / Linf 预算中最小化 sum_i w_i s_i

用最优权重构造加权剩余 MSE 的梯度与 Hessian

执行加权 Newton 更新；真实评估 MSE / MAPE / Cost

算法 C：TAMU

输入：算法 B 的数据；真实负荷与固定电网约束

对评估输入预测 14 节点负荷并反标准化 / 截断

阶段一：用预测负荷调度，保存 p* 和阶段一削减

阶段二：用 p* 和真实负荷求再调度

组合完整 C1 + C2，反向传播得到 v = grad_theta mean(Cost)

其余评分、权重 LP、加权 Newton 更新与算法 B 相同

最后用数值优化器重新计算真实 Cost，不能用代理值代替

方法	更新头部的目标	外层指导信号	条件满足时可以说什么
直接遗忘	无权重剩余 MSE	无额外外层优化	二次、满秩、精确求解时等于剩余集头部重训
PAMU	加权剩余 MSE	MSE/MAPE 的局部梯度	给定权重时可精确拟合二次头；代理目标最优
TAMU	加权剩余 MSE	两阶段 Cost 的局部梯度	同上；须另行检查真实 Cost 和泛化

不显式求逆：iHVP、CG 与阻尼

对于参数维度 p，显式 Hessian 存储约为 $O(p^2)$，直接分解一般约为 $O(p^3)$。算法实际上只需要 $H^{-1}v$，所以应解线性系统 $Ha=v$。

Hessian-vector product 可由自动微分计算：先形成 ∇L，再对标量 $(\nabla L)^T r$ 求梯度，得到 Hr。CG 在正定线性算子上迭代，只需要 HVP，不要求存储完整 H。每次 HVP 要访问训练数据，运行时间还取决于样本量、批大小和迭代次数。

CGInfluenceModule.inverse_hvp 使用 scipy CG；配置 damp 表示实际算子为 $H+\gamma I$。$\gamma>0$ 可以改善某些数值性质，但它会改变更新，不能再直接援引 G6 的无阻尼精确等式。当前 CNN 配置 damp=0；求解容差、浮点误差仍然存在。

gnh 是 Gauss–Newton 类 Hessian 近似开关。当前冻结线性头 + MSE 的普通 Hessian 已是半正定；不应为了“让结果通过”随意切换近似。至少检查 CG 的收敛标志以及 $\| Ha - v \| / max(1, \| v \|)$，不能只看返回了一个向量。

与当前仓库的逐项对应

基准代码版本：reports/cnn-experiments-group-meeting 的 d166da3，继承已修复 Cost 逻辑。下列链接固定到该提交，避免后续分支变动造成定位不一致。

数学步骤	实现与阅读入口
核心训练 / 敏感集特征	return_core_datasets、return_dataset_for_nn_affine
CNN 的 h_ϕ、f_θ	NN_CONV.forward
G5 剩余集更新	eval_unlearn.py
G11 样本评分	eval_unchange.py，114—158 行
G12 权重 LP	eval_unchange.py，215—220 行
G13 加权 Newton	eval_unchange.py，229—238 行
G14 / G15 目标与约束	Operator.stage_one/stage_two
G20 / G21 可微图	Stage_One_Layer、Stage_Two_Layer、SPO
完整 Cost 的可微表达	return_objective 中 MSE_COST
CG / HVP	CGInfluenceModule.inverse_hvp
stest 的实际语义	BaseInfluenceModule.stest

行号是阅读入口，具体函数名为准。标准参数展平顺序是 PyTorch model.parameters() 的 weight 后 bias；解析解中按输出分块的参数需要重排对应，不能把“每输出含 bias 的向量”直接当作原生展平顺序。

两个评分文件为何看起来符号相反

gen_index.py 先算 $M=-H_D^{-1}v$，再用 scale=-1 得到保存的删除影响 $+g_i^T H_D^{-1}v/n$。正值表示删除它预计让指标变差，因此称 helpful。eval_unchange.py 用 H_R 并保存增权分数 $-g_i^T H_R^{-1}v/n$。

除了符号，它们的 Hessian 数据集合也不同，因此不能不加核对地拿旧 influence 文件当作 TAMU 的剩余样本增权分数。还应核对样本顺序、数据划分、核心模型与外层评价标准。

代码中 eps_remain 表示完整权重 w，不是数学上默认以 0 为中心的微小增量。

eps_all[unlearn_index]=-1 是辅助数组里删除扰动的记号；最终加权拟合实际只把剩余样本及其 w 送入 DatasetWithWeight，没有用负权重重新训练删除样本。

连接到你的“温度—预测—Cost”实验

你目前的实验固定一条测试样本、一个节点的温度，改变输入而不改变模型权重：

$$x_j(\tau)=x_j(0)+\tau\,\sigma_{j,train},\tau\in\{-1,-0.5,0,0.5,1\}.$$

原始输入形状为 $(N,1,14,10)$，节点内温度是零基索引 4，选中项为 input[0,0,0,4]。$\sigma_{j,train}$ 在该实验中为编码单位约 0.935414，折算原温度差约 7.936348 K。它与模型原有的全年归一化标准差不是同一个统计量。

对固定模型，小扰动局部可以解释为

$$\frac{dC}{d\tau}=\sigma_{j,train}e_j^T\left(\frac{\partial\hat{d}}{\partial x}\right)^T\nabla_{\hat{d}}C.$$

右侧的 CNN 输入 Jacobian 决定“哪个输入改变哪些预测”；$\nabla_{\hat{d}}C$ 则决定“哪些预测变化具有更大经济后果”。**预测变化最大的输出节点，不在数学上必然等于 Cost 影响最大的节点。** 当多个节点同时改变、活跃约束切换时，单节点贡献还可能有交互，不能随意把逐节点独立影响相加。

TAMU 改变的是预测头 θ，从而可能同时改变基准预测、输入到预测的 Jacobian，以及当前调度所在的活跃区域。即使冻结 CNN 核心不变，输入到 Cost 的响应也可以改变。

既有实测结果对理论的提醒

下表从已经提交的实验 CSV 读取，不是本次新实验。参考样本为 test 0，扰动为 +1 个训练标准差，真实负荷不变。

模型	零扰动 Cost	+1σ 总预测变化 / MW	+1σ 相对自身基准 ΔCost
原始 CNN	588.473549	-0.827542	-6.778363

模型	零扰动 Cost	+1σ 总预测变化 / MW	+1σ 相对自身基准 ΔCost
20% 直接遗忘	680.181358	-0.844525	-7.007316
剩余集重拟合头	680.180885	-0.844474	-7.006892
TAMU，平均 L1=0.1	564.325866	-0.290330	-2.371888

在后续 27 个分层日期的 108 个非零扰动场景中，TAMU 比直接遗忘 Cost 更低的有 106 个；仍有反例。test 1686 的 −1σ 场景中，TAMU 比直接遗忘高约 60.929210。这与“线性代理不等于所有样本的真实 Cost 保证”一致，不能用总体平均改善掩盖。

参考：第一次温度实验；第二次成本归因与多日期实验。这些结果不单独构成论文正确性的证明。

读懂之后必须能够辨认的边界

删除不等于模型表现更差。 被删样本可能 helpful，也可能 harmful；遗忘算法的目标不能仅以“误差是否上升”判断是否成功。

无权重重训不等于加权剩余集拟合。 TAMU 主动改变保留样本的重要性，其拟合目标已经与无权重重训不同。若声称满足某种遗忘保证，必须明确参考算法、可访问的信息和保证定义。

删除数据不意味着历史信息从所有产物消失。 评分在原模型处计算；原模型曾学习删除样本。代码没有提供噪声、分布不可区分性证明或完整成员推断验证，不能据此宣称认证隐私删除。

测试集参与调权会影响评估独立性。 原流程用称为 test 的数据计算 helpful 分数和 PAMU/TAMU 的外层梯度。解释原实验应如实报告；后续严谨研究应预留独立最终测试集，不能把参与调权的指标当作完全独立泛化证据。

当前原数据预处理先全年标准化再划分。 这保留了原复现协议，但会影响泛化评估解释。本次讲义不改变数据处理过程，也不通过重做实验掩盖这一限制。

有限差分是局部检查，不是全局定理。 选择多个扰动步长、检查最优状态、活跃约束和误差尺度；出现折点时，左右导数不同可能是真实现象，不一定是代码错误。

建议怎样核验每一条计算链

环节	具体核验	能排除的问题
头部 MSE	解析解与自动微分梯度/Hessian 对照	目标平均方式、输出顺序错误
直接删除	剩余 Hessian Newton 对照剩余集拟合	错用全数据 Hessian、缩放或符号
影响函数	小幅单样本增权，再拟合，对照预测导数	$1/n$ 丢失、增权与删除符号混淆
数值调度	检查 optimal、约束残差、完整费用分解	取错变量、漏计费用、不可行解

环节	具体核验	能排除的问题
可微 Cost	同一预测输入的有限差分对照反向梯度	断梯度、阶段参数次序、尺度错误
权重 LP	L1/Linf 残差、w=1 基准、目标值	误加权重守恒、把 w 当增量
最终预测头	加权正规方程/CG 残差、重复恢复	权重错配、秩亏、旧文件污染
一般性结论	独立数据、多个时段/种子、保留反例	把单样本偶然结果当普遍规律

随附数学脚本只验证这里的教学例子及标准矩阵恒等式，不重新执行已有电网实验，也不宣称覆盖目标论文全部定理。真正论文复核还需要取得原文，核对其严格假设、误差界、约束与证明。

给导师讲解时可以使用的一段话

“我们把 CNN 分成冻结特征提取器和可遗忘的线性预测头。删除数据后，用剩余集 MSE 的梯度和 Hessian 做一次 Newton 更新；在二次满秩条件下，它等于剩余数据重拟合预测头。为降低删除对性能的损伤，我们用影响函数估计每条保留样本增权对评估指标的影响，再在 L1/Linf 预算内选择样本权重。TAMU 将评估指标从 MSE/MAPE 换成电网两阶段调度的真实费用，通过可微优化层得到参数梯度。这样得到的是局部代理指导的重加权策略，需要用真实 Cost 重新评价；它不保证每个新样本都更便宜，也不能自动等同认证隐私删除。”

应能独立回答以下问题：为什么是 H_R 而非 H_D？为什么增权分数与删除影响符号相反？TAMU 中哪个 Hessian 仍来自 MSE？优化层在哪些条件下可微？为什么 LP 最优不能保证逐样本 Cost 下降？为什么 64 维隐藏表示不等于 64 个物理输入？

附录：实际来源、复现与待补核验

已实际读取的来源

目标论文作者原仓库，包括 README 论文摘要和实现；当前研究仓库固定提交为 d166da3416f2431766251a77a535d873d3c07195。X

P1 作者代码 README。X

P2 作者代码 README。X

P3 配套库 README。X

P4 作者代码 README。X

P5 作者代码 README。X

Wangkun Xu 的可微凸优化学习笔记。该笔记是辅助来源，不替代论文证明。本讲义使用自行整理、维度一致的列梯度推导，而不是照搬笔记中的所有符号。X

可重复运行

从仓库根目录执行：

python reports/tamu_algorithm_guide/verify_derivations.py

python reports/build_tamu_algorithm_guide.py

数学脚本只需要 NumPy；构建器需要 python-docx、NumPy、Matplotlib、PyMuPDF、Pandoc 和 LibreOffice。它使用文档工具环境，不改变项目 .venv 依赖；Word 中的数学公式由 Pandoc 生成原生 Office Math，可在 Word 中编辑。构建器会检查文档压缩结构、原生公式数量、超链接、PDF 的文字边界、教学验证结果及引用的既有实验数值，再生成下载包。

取得原文后的补核验清单

固定 arXiv 版本号，比较其与 IEEE 发表版的题名、符号与算法差异。

核对直接遗忘、PAMU、TAMU 的原文命名、公式号、算法号，不用本讲义编号代替。

对照权重变量的完整权重/扰动约定、Hessian 数据集合、平均化因子和展开锚点。

逐条核对成本梯度存在定理的全部假设、结论范围与证明，而非仅凭摘要判断。

核对发表版电网目标、可行域和各项费用与当前仓库的一致性。

将推荐先修书单与原文参考文献分开标记，补充经全文核对的精确章节与页码。

当前交付的明确范围：已有算法实现得到核对，相关标准推导与教学算例可检查、可重复；未宣称完成无法读取的论文原文及其证明的逐条核验。