论文精读 / 算法推导 / 研究扩展

删除训练数据之后，如何保住电网运行经济性？

Task-Aware Machine Unlearning and Its Application in Load Forecasting

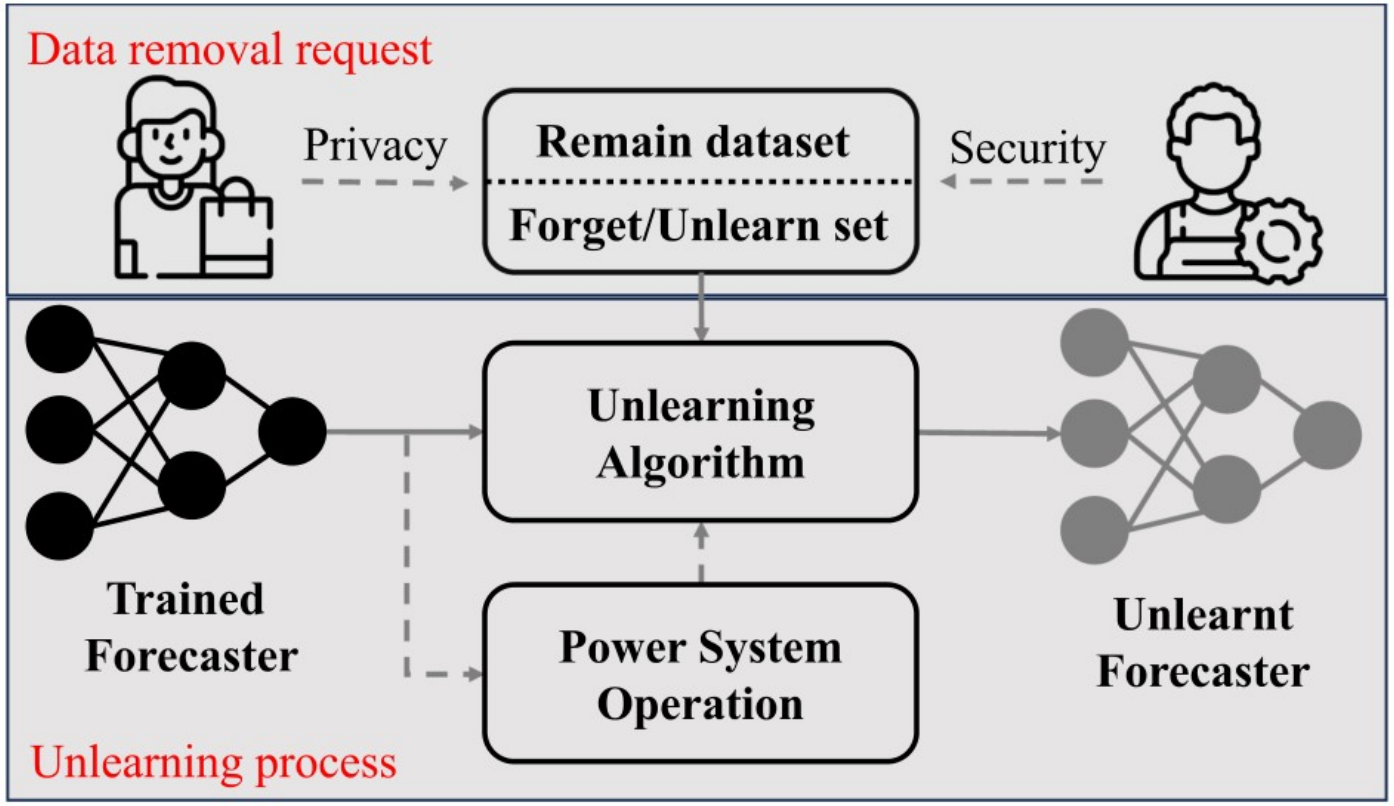
Wangkun Xu · Fei Teng | IEEE TPWRS 39(6), 7178–7189, 2024

直接遗忘 → 任务补偿 → 原文证据 → 特征分析的可能性

25 分钟计划 · 27 页主讲 + 7 页备份 · 依据上传的正式发表版

W. Xu & F. Teng, IEEE TPWRS, 2024 · DOI: 10.1109/TPWRS.2024.3376828

隐私请求与坏数据发现，都可能发生在模型部署之后



隐私驱动：参与者要求移除其数据及影响

安全驱动：错误或恶意数据在训练后被发现

重新训练是参照，但每次从头训练代价较高

论文研究的是训练后的数据影响移除，而非只删除原始记录。

48 秒

训练使用 MSE，评价准则却可以是 MAPE 或运行成本

$$\theta^{\star} = \arg\min_{\theta} L(\theta) = \arg\min_{\theta} \frac{1}{N} \sum_{i \in D} \ell_i(\theta)$$

$$L_{\text{test}}(\theta) = \frac{1}{N_{\text{test}}} \sum_{i \in D_{\text{test}}} \ell^{i}_{\text{test}}(\theta)$$

x：各节点输入特征； y：真实负荷； θ：预测器参数

D = D_unlearn ∪ D_remain；删除集与剩余集互不重叠

训练损失与外层评价的差别，是理解 PAMU / TAMU 的起点

先明确“用什么训练”，再讨论“用什么判断删除后的模型好坏”。

先研究增权扰动，再把权重增量设为 −1 实现删除

$$L_{\text{mod}}(\theta) = L(\theta) + L_{\text{up}}(\theta)$$

$$L_{\text{up}}(\theta) = \frac{1}{N} \sum_{j \in D_{\text{up}}} \varepsilon_j \ell_j(\theta)$$

$$\nabla L_{\text{mod}}(\theta^{\star}_{\text{mod}}) = 0$$

式 (3) 的 ε_j 是相对原样本权重 1 的增量

ε_j > 0 表示增权； ε_j = −1 表示该样本的有效权重变为 0

后文式 (11) 的 ε_i 则直接表示剩余样本的完整权重

原文两处复用了 ε，必须区分“权重增量”和“完整权重”。

Newton 展开包含两层近似，不能把它们合并理解

$$\Delta\theta \simeq -[\nabla^2 L_{\text{mod}}(\theta^\star)]^{-1}\nabla L_{\text{mod}}(\theta^\star)$$

$$\Delta\theta \simeq -[\nabla^2 L_{\text{mod}}(\theta^\star)]^{-1}\nabla L_{\text{up}}(\theta^\star)$$

$$\Delta\theta \simeq -[\nabla^2 L(\theta^\star)]^{-1}\nabla L_{\text{up}}(\theta^\star)$$

式 (5)：在旧最优点展开新目标的梯度

式 (6)：利用原目标梯度为零，保留修改后的 Hessian

式 (7)：扰动较小时，再把修改后曲率近似成原曲率

二次目标下一步精确对应式 (5)–(6)，不自动包含式 (7) 的曲率替换。

直接遗忘在剩余集上做 Newton 更新，线性 MSE 情形可完整

$$\theta^{\star}_{\text{remain}} \simeq \theta^{\star} - H_r^{-1} g_r$$

$$H_r = \sum_{i \in D_{\text{remain}}} \nabla^2 \ell_i(\theta^{\star})$$

$$g_r = \sum_{i \in D_{\text{remain}}} \nabla \ell_i(\theta^{\star})$$

式 (8) 使用剩余集的梯度与 Hessian

分子分母共同的归一化因子在该更新中抵消

完整性参照：同一固定特征模型在剩余集重新拟合

删除后的参数接近重训，不意味着测试性能一定保持不变。

剩余集重训追求均匀拟合， TAMU 另用任务梯度选择样本权重

$$\theta_r = \arg\min_{\theta} \sum_{i \in D_r} \ell_i(\theta), \qquad \theta_{r,\varepsilon} = \arg\min_{\theta} \sum_{i \in D_r} \varepsilon_i \ell_i(\theta)$$

剩余集重训：删除指定数据，最小化剩余样本的均匀 MSE

直接 MU ： 用 Newton 更新加速逼近同一个重训参照

TAMU ： 仅用剩余数据，按运行成本梯度优化权重，再拟合加权 MSE

因此： TAMU 可降低 Cost ，却不保证等于均匀重训或取得认证删除

不同的不只是速度： TAMU 改变剩余数据的训练权重，也改变参照目标。

原文式 (8) 、 (11)–(16) 、 Fig.7 ； 比较表为本汇报整理

PAMU 先线性化测试性能，再重加权剩余样本

$$L_{\text{test}}(\theta^\star + \Delta\theta) \simeq L_{\text{test}}(\theta^\star) + v^T \Delta\theta$$

$$v = \frac{1}{N_{\text{test}}} \sum_{j \in D_{\text{test}}} \nabla \ell^j_{\text{test}}(\theta^\star)$$

$$\Delta\theta_\varepsilon \simeq -H_\varepsilon^{-1} \sum_{i \in D_{\text{remain}}} \varepsilon_i g_i$$

式 (10)：测试指标变化由参数变化的一阶项近似

式 (11)–(12)：剩余样本使用完整权重 ε_i

加权曲率 H_ε = Σ ε_i ∇²ℓ_i，仍然依赖未知权重

PAMU 要补偿的是外层统计指标，而内层训练损失仍是 MSE 。

原文式 (9)–(14)， III； g_i=∇ℓ_i(θ*) 为本页缩写

固定局部曲率后，补偿转成带 L1 / L∞ 预算的线性规划

$$\widetilde{m} = -H_r^{-1} v, \qquad a_i = \widetilde{m}^T g_i$$

$$\min_{\varepsilon} \sum_{i \in D_{\text{remain}}} a_i \varepsilon_i$$

$$\frac{1}{N_{\text{remain}}} \|\varepsilon - \mathbf{1}\|_1 \le \lambda_1, \quad \|\varepsilon - \mathbf{1}\|_\infty \le \lambda_\infty$$

ε 接近 1：用未加权剩余曲率近似式 (14)，得到式 (15)

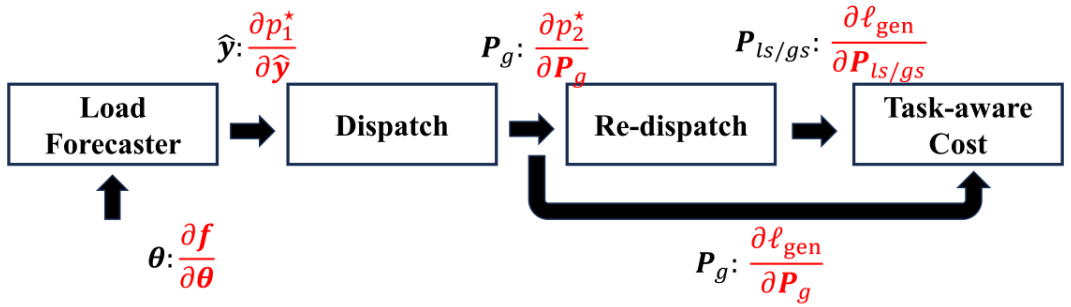
λ∞=1 时，完整权重落在 [0,2]；原文没有权重和固定约束

λ1 或 λ∞ → 0：回到直接完整遗忘

线性目标不取绝对值，允许补偿后的指标优于原始模型。

原文式 (15)–(16) 与 III 末段；λ1 / λ∞ 是补偿预算，不是删除比例

TAMU 把三层运行任务用作外层评价，再沿用重加权算法



$$\min_{\theta} L_{\text{gen}}(\theta) = \frac{1}{N_{\text{test}}} \sum_{i} \ell^{i}_{\text{gen}}(\theta)$$

上层：模型参数对应的平均运行成本

下层：预测驱动调度，再按真实负荷补救

实际遗忘：用 ℓ _gen 替换 ℓ _test，继续求式 (16) 并用式 (12) 更新

式 (17) 的上层变量是 θ；算法并非直接联合求解全部三层变量。

首阶段根据预测负荷进行网络约束经济调度

$$\min_{P_g,\vartheta,s} P_g^T Q_g P_g + c_g^T P_g + c_{ls}\|s\|_1$$

$$B_{\text{bus}}\vartheta = C_g P_g - C_l(\hat{y} - s)$$

$$\underline{P}_g \le P_g \le \overline{P}_g, \quad \underline{P}_f \le B_f\vartheta \le \overline{P}_f$$

s≥0 为保证可行性而设置的负荷松弛；参考相角固定

输入是预测负荷 ŷ，输出包含计划发电 P_g*

Q_g 与 c_g 决定发电的二次、一次成本

预测误差会先改变调度决策，再改变真实运行后果。

第二阶段在真实负荷下惩罚供给不足与过剩

$$\min_{P_{ls},P_{gs},\vartheta} c_{ls2}\|P_{ls}\|_2^2 + c_{gs2}\|P_{gs}\|_2^2 + c_{ls1}\|P_{ls}\|_1 + c_{gs1}\|P_{gs}\|_1$$

$$B_{\text{bus}}\vartheta = C_g(P_g^\star - P_{gs}) - C_l(y - P_{ls})$$

第一阶段计划 P_g* 固定；真实负荷 y 在此时实现

负荷削减 P_ls≥0， generation storage / 过剩处理 P_gs≥0

论文令削减惩罚高于过剩处理惩罚；同样保留线路与相角约束

误差的方向和发生节点会影响成本， MSE 无法单独表达这种不对称。

论文式（18）评价发电与实时补救，不计首阶段松弛罚项

$$\ell_{\text{gen}} = P_g^T Q_g P_g + c_g^T P_g$$

$$+ c_{ls2}\|P_{ls}\|_2^2 + c_{gs2}\|P_{gs}\|_2^2 + c_{ls1}\|P_{ls}\|_1 + c_{gs1}\|P_{gs}\|_1$$

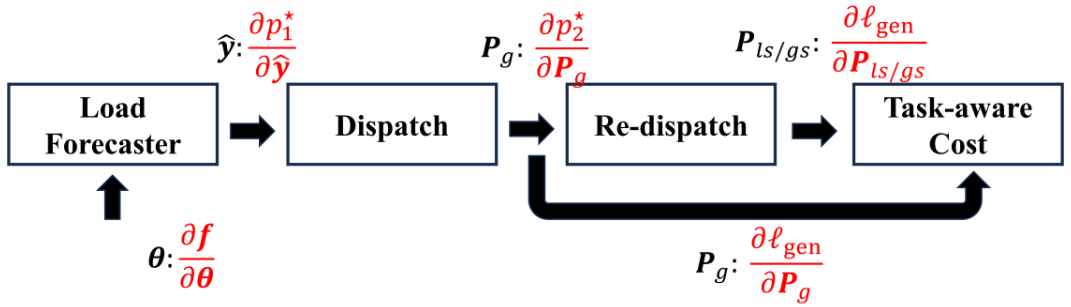
发电成本：由首阶段计划 P_g 决定

补救成本：由第二阶段的 P_ls 、 P_gs 决定

式 (18) 没有首阶段 c_ls ‖ s ‖ ₁；不能无条件等同“两个求解器目标值之和”

若首阶段 s*=0 ，两种口径相等；否则必须分别标注。

链式法则同时包含发电的直接影响和补救的间接影响



$$\frac{\partial \ell_{\text{gen}}}{\partial \theta} = \left[\frac{\partial \ell}{\partial P_g} + \frac{\partial \ell}{\partial P_{ls,gs}} \frac{\partial p_2^\star}{\partial P_g}\right] \frac{\partial p_1^\star}{\partial \hat{y}} \frac{\partial f}{\partial \theta}$$

p1*：预测负荷 → 调度； p2*：调度与真实负荷 → 补救

括号第一项：计划发电本身的成本变化

括号第二项：发电改变后引起的补救成本变化

只反传第二阶段会遗漏第一项；真实负荷 y 在求预测器梯度时固定。

KKT 隐式求导把优化层的 Jacobian 转成线性系统

$$G(u^\star, a) = 0, \qquad u = (x, \lambda, \nu)$$

$$G_u \frac{\partial u^\star}{\partial a} + G_a = 0$$

$$\frac{\partial u^\star}{\partial a} = -G_u^{-1} G_a$$

原文命题 1：正定成本条件与 LICQ 用于梯度存在性论证

附录 B：固定活跃约束组成线性方程，推导最优解对参数的依赖

讲解边界：固定活跃集区间可仿射；跨切换点需额外检查可微性

“可解的凸问题”不自动等于“所有参数位置都有唯一梯度”。

原文 Proposition 1、3、Appendix B；本页隐式公式为讲解重排，反例见 B3

先解一次 iHVP，再给每个剩余样本计算一个影响分数

$$H_r = \sum_{i \in D_{\text{remain}}} \nabla^2 \ell_i(\theta^\star), \qquad v = \frac{1}{N_{\text{test}}} \sum_j \nabla \ell^j_{\text{test}}(\theta^\star)$$

$$H_r u = v, \qquad \widetilde{m} = -u$$

$$a_i = \widetilde{m}^T g_i = -g_i^T u$$

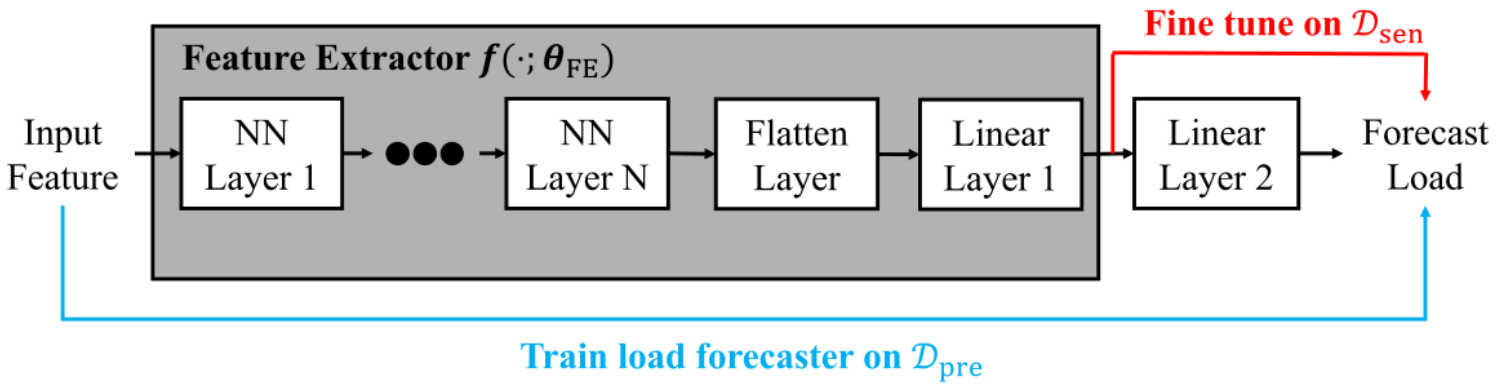
H_r 来自训练 MSE，不是运行 Cost 的 Hessian

CG + Hessian-vector product 可避免显式存储完整 Hessian

换 MSE / MAPE / Cost，主要替换外层梯度 v

本页用 u 区分正负号：式 (21) 的 m 带负号，求 Hu=v 后应取 m=−u 。

NN 的精确特例来自冻结核心后的线性头，而不是全网



D_pre 与 D_sen 不交：先训练非敏感特征提取器

固定提取器，在敏感数据上解析拟合最后线性层

命题 2：固定特征满列秩时， MSE 目标二次且最优解唯一

Tanh 不自动保证满秩；只改线性头也不删除核心中已经存在的影响。

原文 Fig.3 、 Proposition 2 、 Appendix C ； CNN 配置见 Table II

48 秒

PAMU 与 TAMU 共用一套算法，只替换外层评价梯度

① 确定删除集和剩余集，在旧参数处计算样本梯度与曲率

② 计算外层梯度：统计准则 → PAMU ；运行成本 → TAMU

③ 式 (15) 得到固定分数，式 (16) 解权重 LP

④ 用最优权重重新构造加权 Hessian ，按式 (12) 更新

⑤ 报告原指标、 Cost 与到剩余集重训参数的距离

$$\varepsilon^{\star} \rightarrow \theta^{\star}_{\text{remain},\varepsilon}$$

最后更新使用加权 H_ε ；不能把评分用的未加权 H_r 直接沿用。

原文式 (12) 、 (15)–(16) ， IV-A ； CVXPY / CVXPYLayers 与 Torch-Influence 见 IV-C

原文采用 TX-123BT 年度数据与改造的 IEEE 14 节点系统

数据： 2019 年、逐小时；单样本输入 14×10 ，输出 14 节点负荷

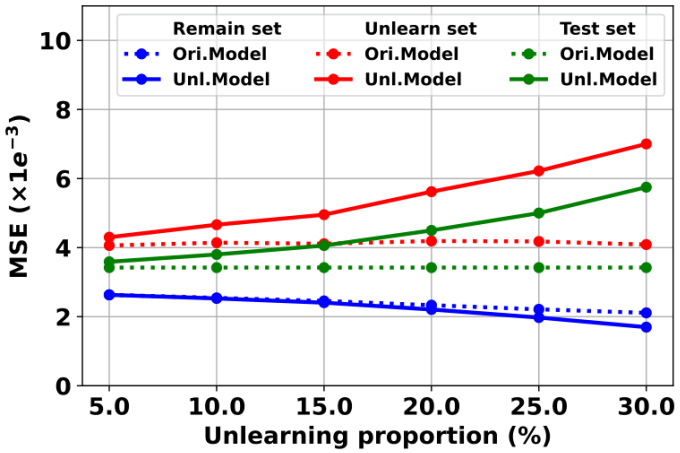
特征： 6 类气象量 + 星期 / 小时的 sin 、 cos 编码

原文划分：前 80% 训练，后 20% 测试

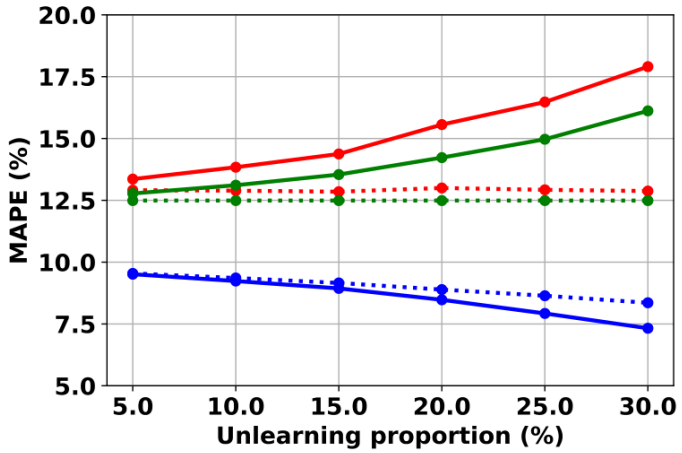
NN ： 训练集前 30% 预训练，其余为敏感数据； 100 epochs 、 Adam 、早停

本页报告论文配置；不把此前复现分支的相反时间划分混入。

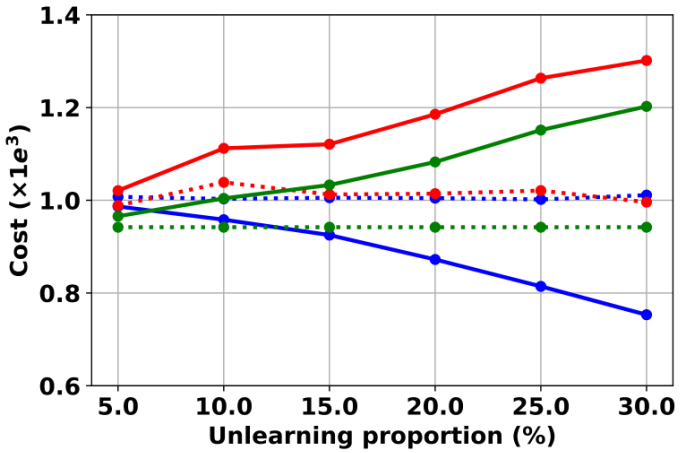
线性模型中，完整遗忘可能使测试 Cost 明显上升



(a) MSE



(b) MAPE



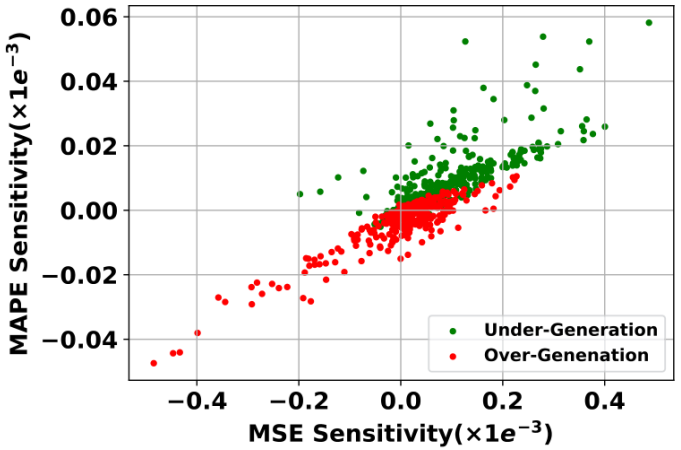
(c) Cost

蓝 / 红 / 绿：剩余集 / 删除集 / 测试集；虚线原始，实线遗忘后

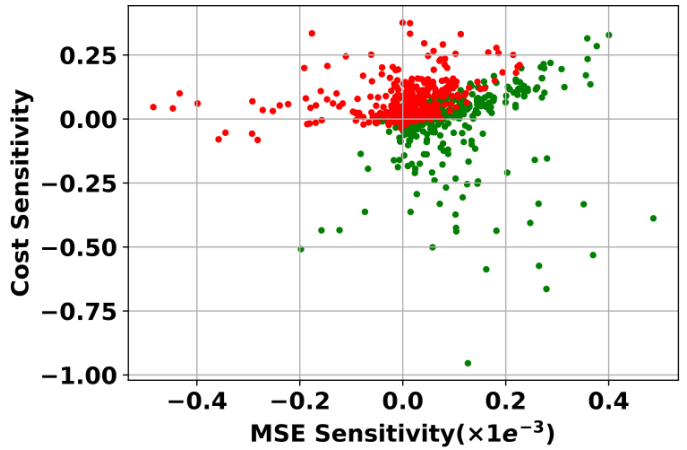
原文示例：删除 20% 训练数据时，测试发电成本约增加 20%

这是本文实验情境下的结果，不是“任何数据删除都会恶化性能”的普遍定理。

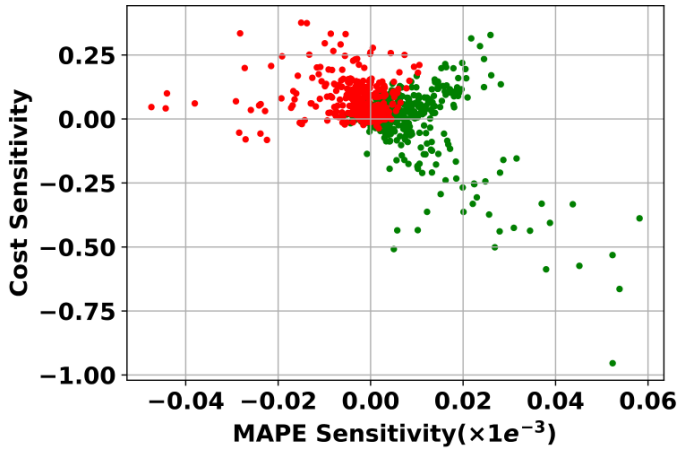
样本对 MSE 的影响，与它对运行 Cost 的影响并不一致



(a) MSE and MAPE ($r = 0.829$)



(b) MSE and Cost ($r = 0.073$)



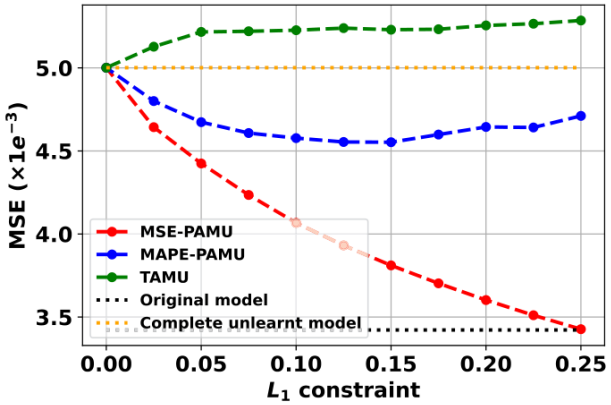
(c) MAPE and Cost ($r = -0.480$)

原文 Pearson r： MSE–MAPE = 0.829； MSE–Cost = 0.073； MAPE–Cost = −0.480

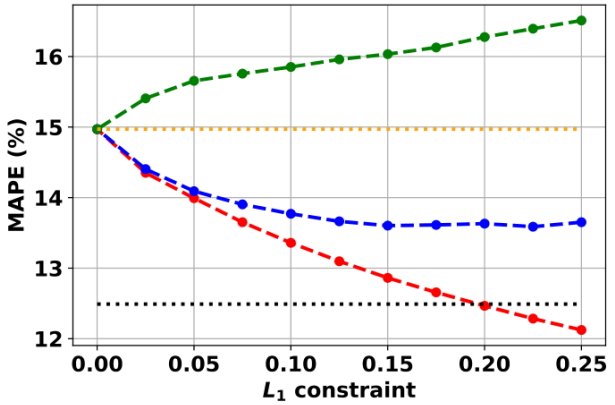
点代表剩余训练样本的影响分数，不是原始输入特征或直接预测误差

统计准则之间较一致，但不能直接代替成本导向的样本价值判断。

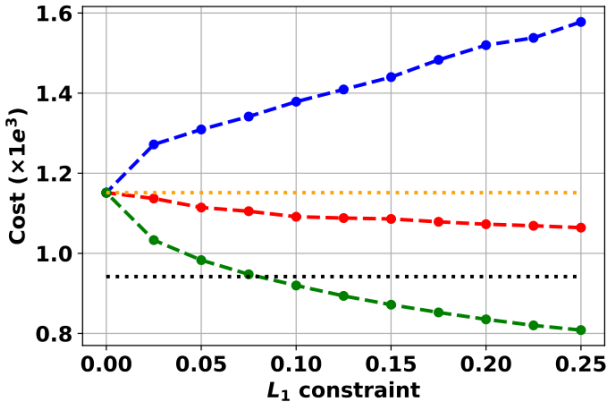
删除 25% 后，放宽重加权预算可改善对应的评价准则



(a) MSE



(b) MAPE



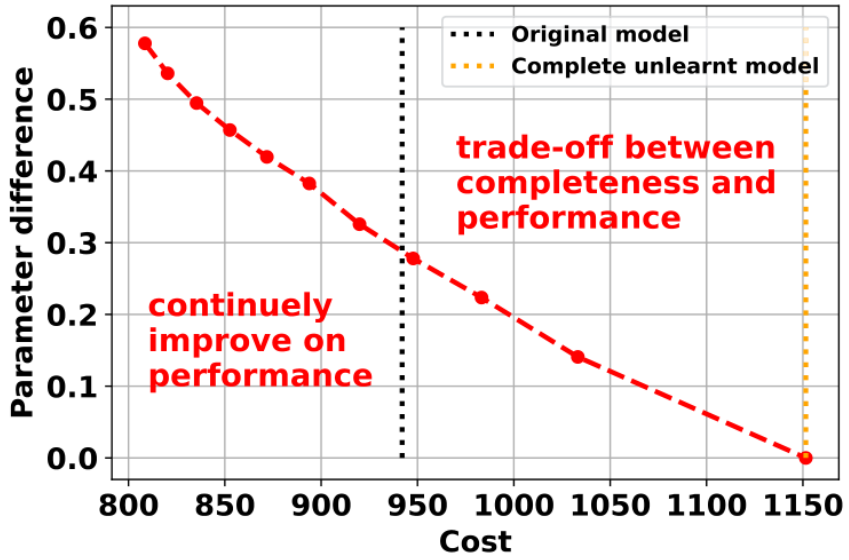
(c) Cost

Fig.6 固定删除比例为 25%；改变 λ1，并设 λ∞=1

MSE / MAPE 导向与 Cost 导向可能呈现不同的改善方向

TAMU 更直接控制 Cost；不应由此声称它在所有指标上都优于 PAMU。

更低的运行 Cost，可能以偏离剩余集重训参数为代价



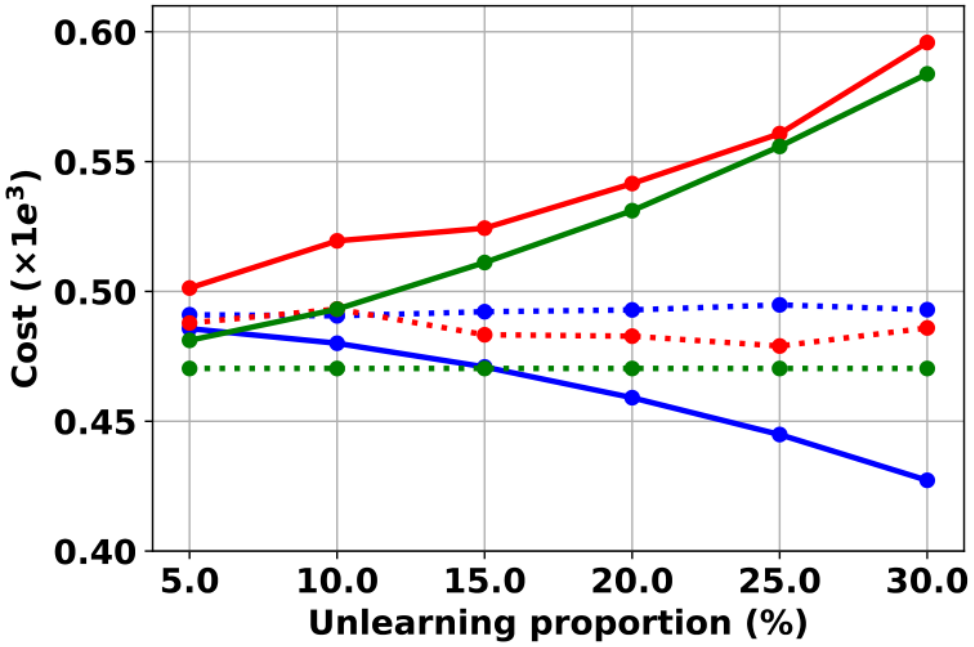
横轴：运行 Cost；纵轴：到重训模型的参数 L2 距离

参数距离为 0 对应完整遗忘参照

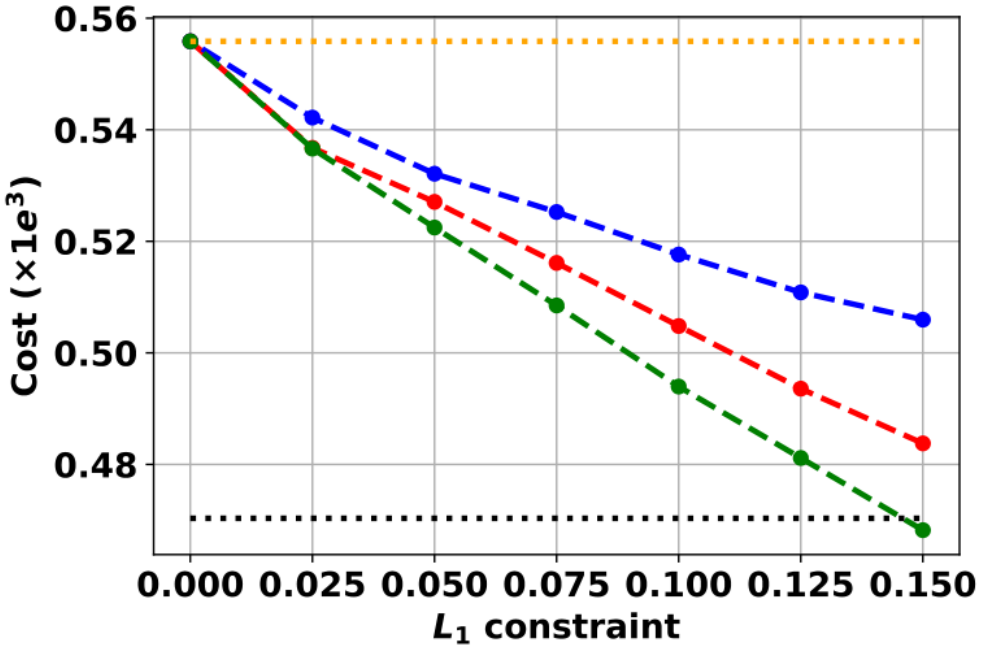
本文把这种变化作为完整性与运行性能的折中来展示

参数距离是本文的完整性代理指标，不等价于差分隐私或认证删除保证。

CNN 结果也显示成本补偿，但精确性范围仍是最后线性层



完整遗忘：蓝剩余 / 红删除 / 绿测试；虚线原始



补偿：红 MSE-PAMU / 蓝 MAPE-PAMU / 绿 TAMU

NN 中统计与成本的冲突较弱；作者将其解释为预测更准确，但不是普遍保证。

原文 Fig.8 裁取右上 / 右下； V-C 与 Appendix E ；完整 Fig.8–9 见 B1–B2

可以推进到特征分析，但“特征归因”不同于“特征遗忘”

$$x \longrightarrow h_\phi(x) \longrightarrow \hat{y} = Wh_\phi(x) + b \longrightarrow p_1^* \longrightarrow p_2^* \longrightarrow C$$

$$S_{\text{pred},k} = \frac{\partial \hat{y}}{\partial x_k}, \qquad S_{C,k} = \frac{\partial C}{\partial \hat{y}} \frac{\partial \hat{y}}{\partial x_k}$$

样本层：哪条训练记录影响参数与 Cost？ 论文已研究

特征层：同一输入的哪个维度影响预测与 Cost？ 可用链式求导扩展

层级层：对隐藏单元 / 通道的归因，回答模型内部如何传递影响

原文按样本重加权；输入、隐藏表示和训练记录属于不同的分析对象。

先测输入响应，再研究训练样本中的某个特征如何影响 Cost

$$x^{(\delta)} = x + \delta \sigma_k e_k, \qquad \delta \in \{-1, -0.5, 0, 0.5, 1\}$$

$$\frac{d\theta^\star}{dx_{ik}} = -H^{-1} \frac{\partial^2 L}{\partial \theta \, \partial x_{ik}}, \qquad \frac{dC}{dx_{ik}} = -\nabla_\theta C^T H^{-1} \frac{\partial^2 L}{\partial \theta \, \partial x_{ik}}$$

第一步：固定真实负荷、模型和约束，仅扰动一个节点的温度

第二步：比较原始 / 直接 MU / 重训 / TAMU 的预测及 Cost 响应

进一步：混合二阶导数连接“训练记录中的特征”与任务影响

可行性来自可微链路；局部性、特征相关性、秩与优化活跃集是主要边界。

研究扩展与局部驻点隐式推导，非原文结果； σ 为对应训练特征标准差

论文把“移除影响”推进到“按运行任务补偿剩余数据”

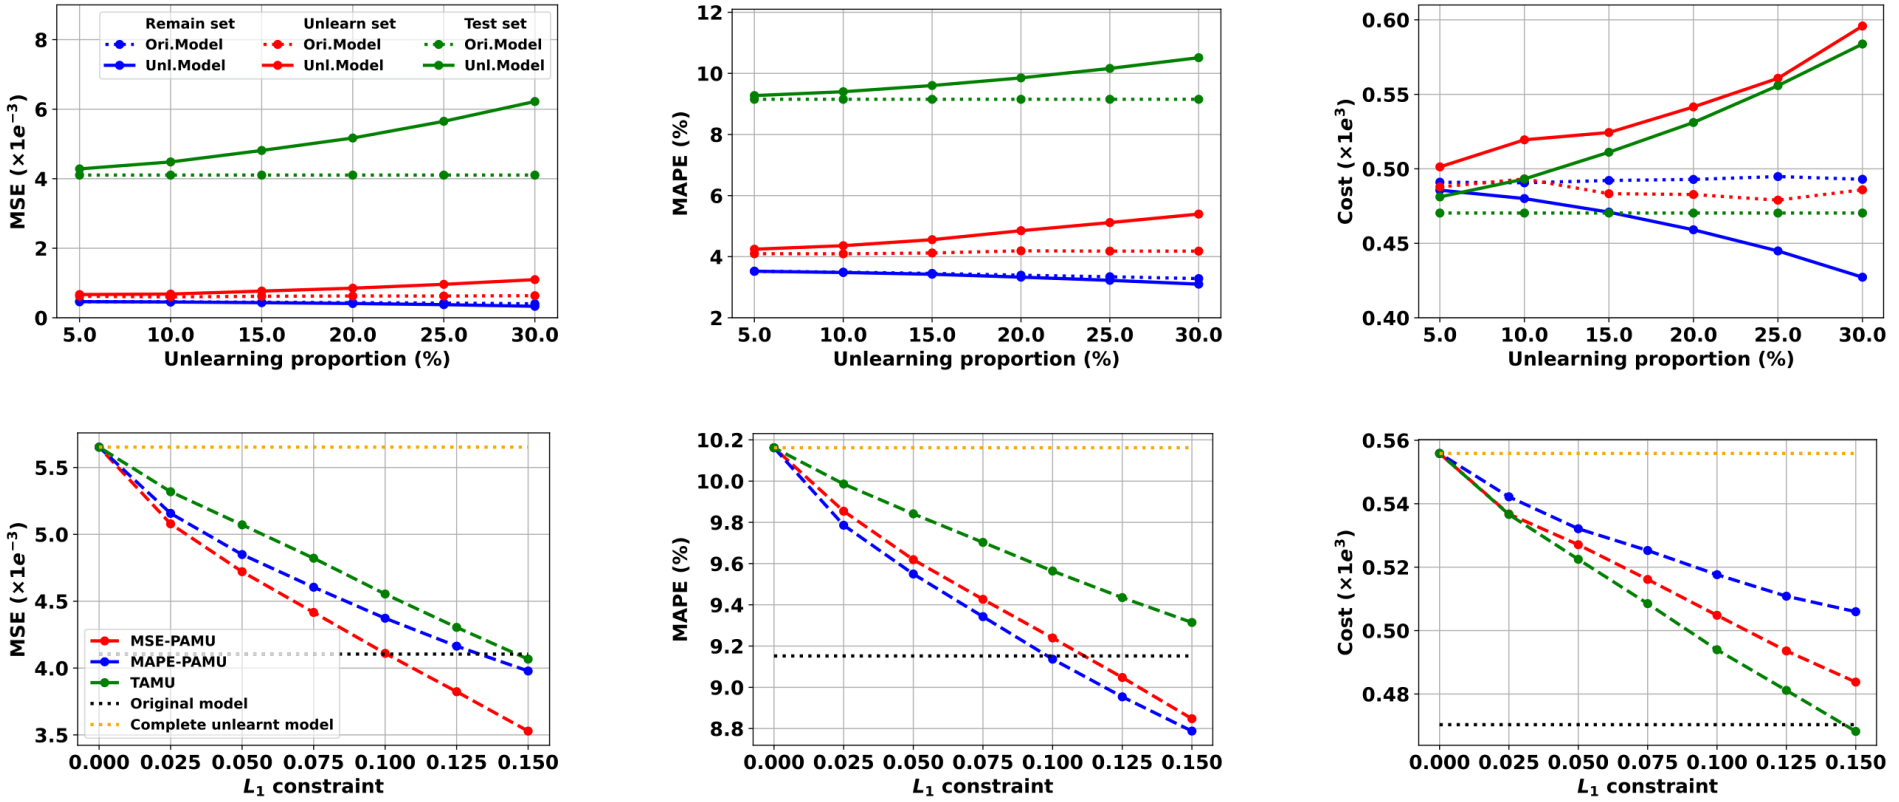
01 直接 MU 可加速逼近均匀剩余集重训； TAMU 改变补偿目标

02 Cost 梯度把样本价值与电网经济性连接起来

03 下一步：区分输入归因、层归因与训练特征影响，再检验遗忘前后变化

最重要的连接：样本梯度 × 训练曲率修正 × 运行成本梯度。

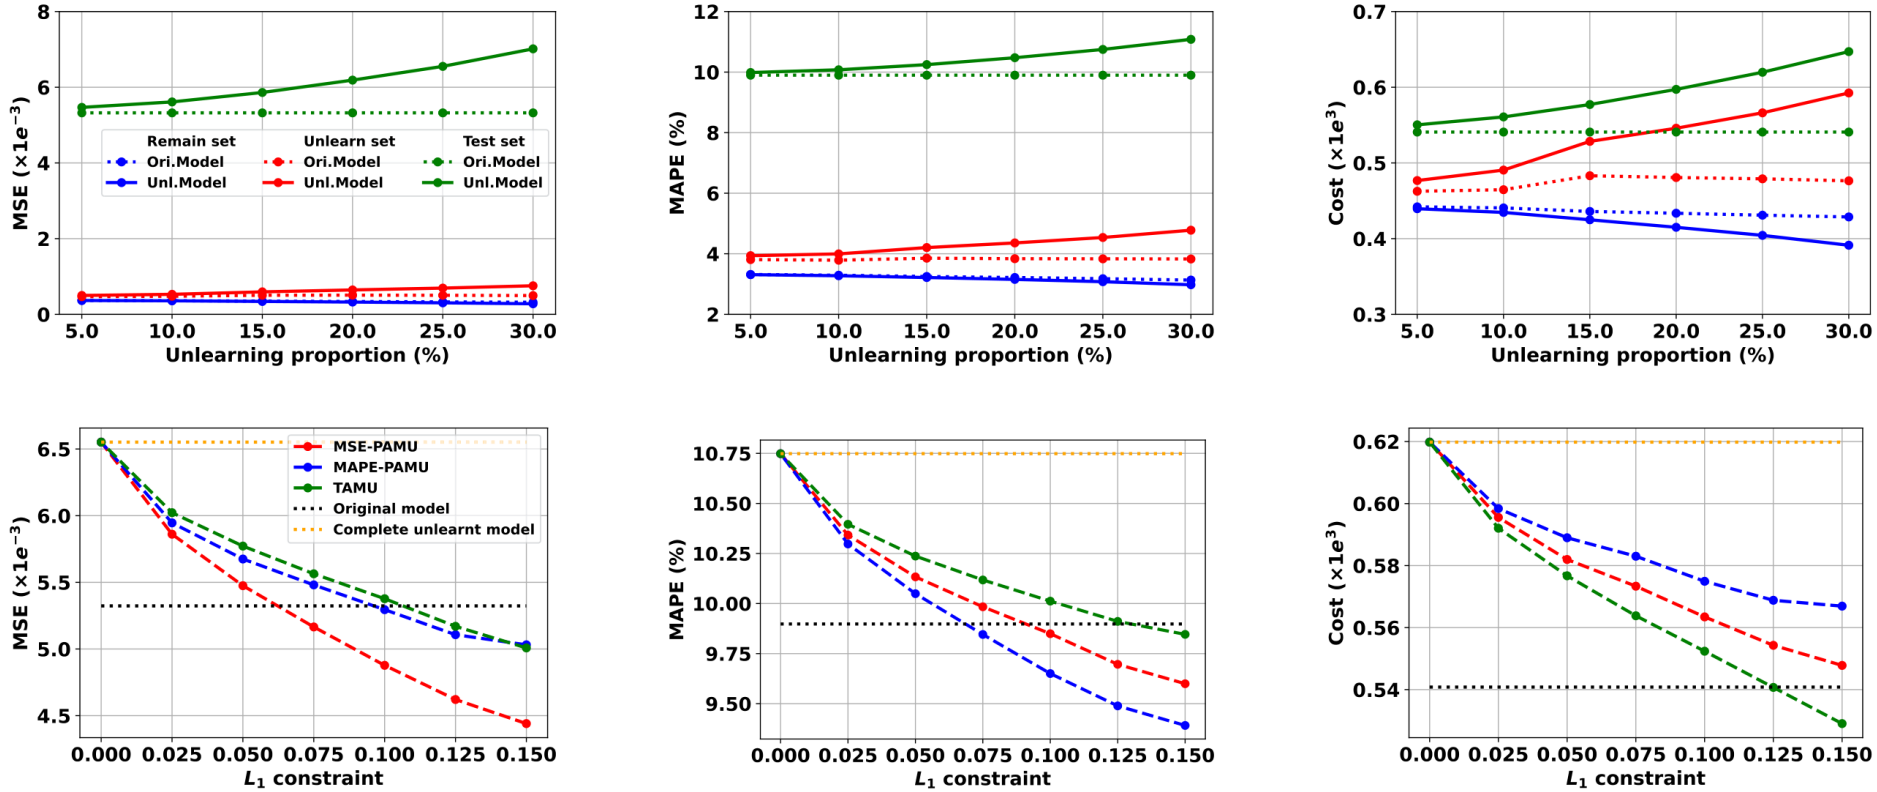
备份 B1 | CNN：保留原文六个子图的完整比较语境



第一行：完整遗忘；第二行： PAMU / TAMU 随重加权预算变化

完整性针对固定特征后的线性头；正文 V-C 报告 NN 上的指标冲突较弱。

备份 B2 | MLP-Mixer：同样观察到重加权补偿效果



第一行：完整遗忘；第二行： PAMU / TAMU 的统计与任务指标

图中结论限于作者的数据、模型与实验设置，不是跨数据集保证。

备份 B3 | 固定活跃集可仿射，不等于跨切换点处处可微

$$x^\star(z) = \arg\min_{x \geq 0} \tfrac{1}{2}(x - z)^2 = \max(0, z)$$

$$Q = 1 > 0, \qquad \nabla(-x) = -1 \neq 0$$

$$\frac{dx^\star}{dz} = 0 \ (z < 0), \qquad \frac{dx^\star}{dz} = 1 \ (z > 0)$$

z=0 处活跃约束梯度非零， LICQ 仍可满足，但左右导数不同

附录 B 的仿射表达使用最优点对应的活跃约束矩阵

补充解读：分段仿射结构不自动给出全局恒定 Jacobian

这是独立数学反例，不是作者实验；不能把命题 1/3 读成无条件全局光滑保证。

对原文 Proposition 1 、 3 与 Appendix B 的条件辨析；反例为本汇报补充

备份 B4 | 最后线性层的唯一解取决于特征矩阵的秩

$$L(\Theta) = \frac{1}{N_{\text{sen}} n} \|Y - X\Theta\|_F^2$$

$$H \propto \text{diag}(X^T X, \ldots, X^T X)$$

$$\Theta^\star = (X^T X)^{-1} X^T Y$$

原文命题 2 假设 X 满列秩；偏置若参与拟合，应加入常数特征列

加权后还要检查 W^(1/2)X 的秩；零权重可能造成退化

若改用广义逆或加正则项，必须明确新的求解协议与目标

“使用 Tanh” 或“它是线性层”本身都不等于已验证 Hessian 可逆。

备份 B5 ｜原文、算法重述与此前代码复现的四个口径区别

成本：式 (18) 不含首阶段 s 松弛惩罚；此前代码总目标可包含它

划分：论文前 80% 训练；此前复现代码采用后 80% 训练

符号：式 (21) 含负号；以 $Hu=v$ 、 $m=-u$ 保持计算一致

保证：参数距离代理 ≠ 隐私认证；测试集参与权重优化也需独立评估讨论

本版原图与数字只来自上传论文；温度扰动等后续实验没有混入。

备份 B6 | 原文 CNN 与 MLP-Mixer 结构表

TABLE II
STRUCTURE OF THE CNN LOAD FORECASTING MODEL

Conv Layer 1	8: $3 \times 3 + 1 + 1$ (ReLU)
Conv Layer 2	8: $4 \times 4 + 2 + 1$ (ReLU)
Linear Layer 1	64 (tanh)
Linear Layer 2	14 (No activation)

For the convolutional layer, $(k : W \times H + S + p)$ represents the k number of filters, kernel size $w \times h$ with s stride and p padding in both sides. For the linear layer, the number indicates the output size. The activation function is written in bracket.

TABLE III
STRUCTURE OF THE MLP-MIXER LOAD FORECASTING MODEL WITH EXACT SETTINGS IN [43]

No. of Patches	2
No. of Mixer Blocks	2
MLP	64 (GeLU)
Linear Layer 1	64 (tanh)
Linear Layer 2	14 (no activation)

One basic mixer block contains two MLP blocks. Each MLP block contains two linear layers and one activation function between them. We also apply layer norms before each MLP block and pooling layers wherever necessary.

CNN： 两层卷积 + 64 维 Tanh 隐藏层 + 14 维线性输出

MLP-Mixer： patch / mixer 配置以 Table III 为准

完整训练配置在 Appendix D；主讲不展开每个结构超参数。

备份 B7 ｜原文已核验，视频模板仍待可读取材料

原论文：上传的 IEEE 正式版， 12 页；原图 Fig.1–9 已逐一定位

MIT How to Speak： 沿用开场承诺、叙事递进、实质性总结等设计

B 站 BV1WF411Y73C： 页面与接口均 403 ，未观看，未声称已匹配模板

如需精确匹配视频版式，请提供视频或关键页截图；论文内容无需再等待。