Task-Aware | 25 分钟逐页讲稿

27 页主讲计划 1500 秒，另有 7 页问答备份。时间为演讲计划，未做实际录音测量。主依据为上传的 12 页 IEEE 正式版；扩展研究与原文结果分别标注。

01 / S01 删除训练数据之后，如何保住电网运行经济性？

建议时间：00:00–00:30

今天汇报的论文是徐旺坤和滕飞发表于 IEEE Transactions on Power Systems 的 Task-Aware Machine Unlearning。核心问题是：负荷预测器已经训练并部署后，如果部分训练数据需要删除，如何在移除其影响的同时尽量保住运行经济性？这次以你上传的十二页正式发表版为准，公式、图号和结果均与该文件核对，不再使用此前代码工作稿代替原文。接下来分四部分：直接遗忘，剩余样本重加权，电网成本的可微计算，以及作者实验给出的证据。主讲计划二十五分钟，备份推导不计入。

带走：贡献不只是“删得快”，还要解释删除、性能与运行成本的取舍。

来源：上传的 IEEE 正式发表版，PDF 1–12 页；DOI 10.1109/TPWRS.2024.3376828

02 / S02 隐私请求与坏数据发现，都可能发生在模型部署之后

建议时间：00:30–01:18

先看论文原图一。上方表示出于隐私或安全原因提出的数据删除请求，下方是对已训练预测器的更新流程。联邦学习、差分隐私或鲁棒训练主要在训练前和训练中提供保护，但系统运营者也可能在部署后才发现数据错误，或收到用户撤回请求。删除磁盘上的数据不会自动消除它在模型中的影响。从剩余数据重新训练是一个参照做法，却可能很贵。论文还提出两个缺口：完整遗忘可能损失有用的预测信息；即使统计误差补偿好了，也未必补偿电网运行成本。这两点推动了后面的 PAMU 和 TAMU。

带走：论文研究的是训练后的数据影响移除，而非只删除原始记录。

来源：原文 Fig.1，PDF p.3 / 期刊 p.7180；引言 I-B、Table I

03 / S03 训练使用 MSE，评价准则却可以是 MAPE 或运行成本

建议时间：01:18–02:06

论文把训练损失和测试准则明确分开。式一用所有训练样本的平均损失拟合参数，本文采用 MSE。式二评价的是测试集指标，它可以是 MSE，也可以是 MAPE，之后还会变成运行成本。这个区分很重要：TAMU 并不意味着最后把整个神经网络改成直接最小化 Cost 训练。删除时，我们把原数据分成删除集和剩余集；影响函数和重加权要回答，剩余样本怎样改变参数，参数又怎样改变选定的外层评价。这里的测试集是作者原文的写法，独立验证与测试协议将在讨论页另行辨析。

带走：先明确“用什么训练”，再讨论“用什么判断删除后的模型好坏”。

来源：原文式 (1)–(2)，II-A；本页记号按原文简化重排

04 / S04 先研究增权扰动，再把权重增量设为 −1 实现删除

建议时间：02:06–02:58

影响函数从改变样本权重入手。原来每个样本权重是 1，式三再加一个增量 epsilon。因此 epsilon 为正代表额外强调这个样本，epsilon 等于负一才是完全撤掉它的损失贡献。对新的最优解，梯度应当为零，这就是式四的驻点条件。接下来所有参数变化近似都从它推导。这里有一个阅读陷阱：到 PAMU 的式十一，作者又用 epsilon 表示剩余样本的完整权重，基准值变成 1。如果把这两种 epsilon 混在一起，就会把删除样本设为负权重，或把均匀重加权误认为零权重。讲解时务必先说清上下文。

带走：原文两处复用了 ε，必须区分“权重增量”和“完整权重”。

来源：原文式 (3)–(4)、II-C 与式 (11)，PDF pp.3–4

05 / S05 Newton 展开包含两层近似，不能把它们合并理解

建议时间：02:58–04:07

这一页是算法最关键的推导。先把新目标的梯度在旧最优点做一阶 Taylor 展开，解这个近似方程，就得到式五的 Newton 更新。因为原目标在旧最优点的梯度为零，新目标的梯度就只剩

增权部分，于是得到式六。到这里，Hessian 仍然是修改后的目标。作者接着说，如果增权很小或涉及样本很少，可以进一步把它替换成原目标的 Hessian，得到式七。这是第二次近似。固定特征的线性回归配 MSE 时，目标本身就是二次的，因此式五和式六可以精确到达新最优点；但如果额外替换了曲率，精确性一般就不再自动成立。负号表示沿新目标梯度的反方向纠偏，Hessian 的逆则校正不同参数方向的曲率尺度。

带走：二次目标下一步精确对应式 (5)–(6)，不自动包含式 (7) 的曲率替换。

来源：原文式 (5)–(7)，II-B；II-C 前的精确性说明

06 / S06 直接遗忘在剩余集上做 Newton 更新，线性 MSE 情形可完整

建议时间：04:07–05:12

把删除样本的权重增量设成负一后，论文得到式八。它也可以直接理解成：旧参数对剩余集未必还是最优，所以计算剩余集梯度和 Hessian，再做一次 Newton 纠偏。注意 Hessian 来自剩余集，不是原完整集。这里使用求和记号；如果两者同时改成平均，更新量中的共同因子会抵消。对于固定特征、可逆曲率的线性 MSE 问题，这一步与剩余集重拟合一致，因此作者称其完整。这个完整性定义描述参数与重训的关系，不等于统计性能不变，更不是自动取得隐私认证。后面的原图四会看到：同一完整更新在剩余集上拟合更好，却可能让测试集 Cost 上升。

带走：删除后的参数接近重训，不意味着测试性能一定保持不变。

来源：原文式 (8)，II-C；线性模型的完整性结论与 Fig.4 验证

07 / X01 剩余集重训追求均匀拟合，TAMU 另用任务梯度选择样本权重

建议时间：05:12–06:17

必须把两个维度分开。第一个维度是求解方法：从头重训用迭代或解析方法求剩余集最优参数，直接 MU 用 Newton 更新快速计算同一个参照。在固定特征且满秩的二次损失下，二者可以完全一致。第二个维度是优化目标：传统剩余集重训默认每条剩余样本同权，而 TAMU 利用运行成本梯度，给不同剩余样本不同的权重。最终它仍在拟合 MSE，但拟合的是加权 MSE。因此不能把 TAMU 仅说成更快的重训，也不能说它直接重新训练整个 CNN 来最小化成本。预

算为零时回到均匀权重；预算放开后，成本可能改善，但到均匀重训的参数距离可能增大。是否满足严格遗忘定义，需要另做保证或攻击评估。

带走：不同的不只是速度：TAMU 改变剩余数据的训练权重，也改变参照目标。

来源：原文式 (8)、(11)–(16)、Fig.7；比较表为本汇报整理

08 / S07 PAMU 先线性化测试性能，再重加权剩余样本

建议时间：06:17–07:09

直接遗忘会损失一些对测试集有帮助的信息，PAMU 试图用剩余数据补偿。第一步是把测试指标在旧参数附近线性化：参数变化与外层梯度 v 做内积，近似表示指标变化。第二步是给剩余样本完整权重 epsilon，通过加权训练目标计算参数更新。式十二里面，样本梯度和 Hessian 都受权重影响。因此如果现在直接优化权重，逆矩阵也跟着变化，还不是一个简单线性问题。作者下一步近似加权曲率，才得到可预先计算的样本分数。这个过程解释了为什么权重不能无限偏离 1，也解释了局部模型的适用范围。

带走：PAMU 要补偿的是外层统计指标，而内层训练损失仍是 MSE。

来源：原文式 (9)–(14)，III；g_i=∇ℓ_i(θ*) 为本页缩写

09 / S08 固定局部曲率后，补偿转成带 L1 / L∞ 预算的线性规划

建议时间：07:09–08:23

当权重接近 1 时，作者用未加权的剩余集 Hessian 近似加权 Hessian，于是 m 向量可以提前计算，每个样本只剩一个固定分数 a i。权重优化就成为线性目标加两个范数约束。平均 L1 预算控制总改动量，L 无穷预算控制单个样本的改动。论文实验把后者设为 1，所以完整权重可以在 0 到 2 之间变化，没有额外要求权重和等于剩余样本数。当两个预算之一趋向 0，权重被锁定在 1，回到直接完整遗忘。预算放宽后，可以改善外层指标，但参数会偏离剩余集均匀重训模型。作者还特意不对目标取绝对值，因此允许指标超过原始模型，而不仅仅恢复到原水平。这里的预算和删除比例必须分别报告。

带走：线性目标不取绝对值，允许补偿后的指标优于原始模型。

来源：原文式 (15)–(16) 与 III 末段；λ1 / λ∞ 是补偿预算，不是删除比例

10 / S09 TAMU 把三层运行任务用作外层评价，再沿用重加权算法

建议时间：08:23–09:15

TAMU 并不是另起炉灶设计一种完全不同的删除器，而是把 PAMU 的外层评价替换成运行成本。原图二把式十七画成预测、调度、再调度的顺序层。要特别注意，式十七上层写的是模型参数 theta，不是样本权重。它定义了怎样评价一个预测器的任务表现；实际遗忘仍然按 PAMU 的路线，先求这个任务指标对参数的梯度，再用式十六求剩余样本权重，最后按式十二更新参数。因此不要把它讲成每次遗忘都直接联合求解一个庞大的三层规划，也不要误认为训练网络的全部层都改用 Cost 损失。

带走：式 (17) 的上层变量是 θ；算法并非直接联合求解全部三层变量。

来源：原文 Fig.2、式 (17)、式 (19) 后的算法说明，IV-A

11 / S10 首阶段根据预测负荷进行网络约束经济调度

建议时间：09:15–10:03

第一阶段是带网络约束的经济调度。目标函数包含发电二次成本、线性成本，以及为保证可行性引入的松弛惩罚。功率平衡把预测负荷减去松弛量后，与机组注入相匹配；还有机组出力上下界、线路潮流上下界和参考相角。这个优化的输入是预测负荷，输出是计划发电。它没有使用未来真实负荷来提前修正预测，所以后面还需要第二阶段。这里把松弛变量 s 与第二阶段实际负荷削减 P ls 分开命名，避免误以为它们是同一个变量。稍后解释式十八时，还要区分优化目标和最终评价指标。

带走：预测误差会先改变调度决策，再改变真实运行后果。

来源：原文 Appendix A 的 dispatch 模型，PDF p.9 / 期刊 p.7186

12 / S11 第二阶段在真实负荷下惩罚供给不足与过剩

建议时间：10:03–10:59

第二阶段把第一阶段的发电计划作为给定参数，再用真实负荷检查不匹配。供给不足由负荷削减变量表达，过剩由原文称 generation storage 的变量处理；两种变量都带线性和二次惩罚。论文明确让削减成本高于过剩处理成本，因此相同绝对误差，在低估与高估两种方向上可能带来不同经济后果。线路约束又使误差的位置变得重要。这里的 storage 只在单时段补救模型中出现，没有电池荷电状态和跨时段动态，不能把它讲成已经包含完整储能运营模型。这些物理和成本结构，是统计误差与任务指标不完全一致的原因。

带走：误差的方向和发生节点会影响成本，MSE 无法单独表达这种不对称。

来源：原文式 (17)、Appendix A 的 redispatch 模型，PDF pp.5、9

13 / S12 论文式 (18) 评价发电与实时补救，不计首阶段松弛罚项

建议时间：10:59–11:51

这一页专门澄清一个容易在复现时混淆的细节。论文式十八的评价成本由发电成本、第二阶段削减成本和过剩处理成本构成，没有把首阶段为了保证可行性而设置的 s 松弛罚项再次计入。因此不能无条件把论文 Cost 写成两个优化器返回的目标值之和。如果第一阶段最优 s 确实为零，两种口径当然相等；若非零，就要分别报告。这不是说调度问题可以删掉松弛罚项，而是说求解时的目标与最终评价指标需要按原文区分。新版 PPT 使用式十八，不把此前修复仓库中包含首阶段松弛的总目标口径静默搬过来。

带走：若首阶段 s*=0，两种口径相等；否则必须分别标注。

来源：原文式 (18) 对照 Appendix A；此处已纠正旧工作稿的成本口径

14 / S13 链式法则同时包含发电的直接影响和补救的间接影响

建议时间：11:51–12:47

现在看原图二中标红的梯度。调度和补救是两个顺序连接的最优解映射：p 一把预测负荷映射为计划发电，p 二再把计划和真实负荷映射为补救变量。式二十的括号里有两条路径。第一条是改变计划发电直接改变发电成本；第二条是计划改变引起补救变量改变，进而影响补救成本。两条路径相加，再乘第一阶段对预测负荷的导数，最后乘预测器对参数的导数。如果只计

算第二阶段反向传播，就漏掉发电成本的直接项。真实负荷和系统参数在这里作为场景条件保持固定，我们求的是预测器参数的影响，而不是改变实际发生的需求。

带走：只反传第二阶段会遗漏第一项；真实负荷 y 在求预测器梯度时固定。

来源：原文 Fig.2、式 (19)–(20)，PDF p.5 / 期刊 p.7182

15 / S14 KKT 隐式求导把优化层的 Jacobian 转成线性系统

建议时间：12:47–14:09

约束优化的最优点没有普通显式前向公式，梯度要从最优性条件取得。把原始变量、对偶变量组成 u，把输入参数记为 a，KKT 条件写成 G 等于零。对输入求导，得到一个线性方程；在对应 Jacobian 可逆的局部条件下，解它就能得到最优点的导数。论文命题一要求二次成本正定、削减与过剩二次系数为正，以及最优点的 LICQ。附录 B 的证明把当前活跃约束挑出来，解出原始和对偶变量。这里必须加一句审慎解释：固定活跃集区域内，最优解对仿射参数确实呈仿射关系，Jacobian 在该区域内是常数；跨活跃集切换点时，不应笼统讲成全局同一个仿射函数或处处可微。备份页给出一个一维强凸 QP 反例，说明一般的 Q 正定和 LICQ 本身不足以排除拐点。这属于我们的数学辨析，不是作者实验结果。

带走：“可解的凸问题”不自动等于“所有参数位置都有唯一梯度”。

来源：原文 Proposition 1、3、Appendix B；本页隐式公式为讲解重排，反例见 B3

16 / S15 先解一次 iHVP，再给每个剩余样本计算一个影响分数

建议时间：14:09–15:05

论文需要 Hessian 的逆乘一个向量，但没有必要真的构造完整逆矩阵。先用平均外层梯度 v 作右端项，解 H r 乘 u 等于 v，再取 m 等于负 u，最后与每个样本梯度做内积。CG 配合 Hessian 向量积，可以避免显式存储整个 Hessian。训练目标还是 MSE，所以这里的 Hessian 不是 Cost 的二阶导数；外层指标改变，主要改变的是 v。原文式二十一在 m 定义前有负号，式二十二的线性系统写法若继续沿用同名 v，会出现符号上的不一致。因此我们用独立变量 u 写出

一致的计算过程，不把负号丢掉。这个向量也给出了为什么重加权可以高效进行：不必为每个样本单独重训一个模型。

带走：本页用 u 区分正负号：式 (21) 的 m 带负号，求 Hu=v 后应取 m=−u。

来源：原文式 (15)、(21)–(23)，IV-C；符号一致性说明见 B5

17 / S16 NN 的精确特例来自冻结核心后的线性头，而不是全网

建议时间：15:05–16:06

直接把影响函数用于整个神经网络会遇到非凸、Hessian 奇异和近似质量的问题。论文采用迁移学习式结构：先用不含用户敏感信息的 D pre 训练核心，再把它固定成特征提取器，最后只用 D sen 解析拟合线性层二。原图三中最后一层没有激活函数，因此固定特征之后，其 MSE 目标是二次的。命题二还要求提取特征满列秩，这样最优解才唯一。作者避免在线性层一使用 ReLU，是为了减少零特征和退化风险，但换成 Tanh 并不自动证明满秩。这里的完整遗忘只针对满足条件的线性头；如果核心曾使用要删除的数据，单改最后一层并不足以移除核心里的影响。

带走：Tanh 不自动保证满秩；只改线性头也不删除核心中已经存在的影响。

来源：原文 Fig.3、Proposition 2、Appendix C；CNN 配置见 Table II

18 / S17 PAMU 与 TAMU 共用一套算法，只替换外层评价梯度

建议时间：16:06–16:54

现在把前面的式子串起来。先选定删除数据，计算旧参数上的剩余样本梯度与曲率。再计算外层梯度：用 MSE 或 MAPE 就是 PAMU，用两阶段运行成本就是 TAMU。借助式十五构造分数，式十六求最优权重。最后一步必须回到式十二，重新使用加权的 Hessian 更新参数，不能直接沿用评分时冻结的未加权曲率。评价时还应记录到剩余集重训模型的参数距离，因为性能改善可能伴随完整性参照的偏离。作者用 CVXPY 求优化问题，以 CVXPYLayers 和自动微分处理运行层梯度，并用修改过的 Torch-Influence 实现相关计算。

带走：最后更新使用加权 H_ε；不能把评分用的未加权 H_r 直接沿用。

来源：原文式 (12)、(15)–(16)，IV-A；CVXPY / CVXPYLayers 与 Torch-Influence 见 IV-C

19 / S18 原文采用 TX-123BT 年度数据与改造的 IEEE 14 节点系统

建议时间：16:54–17:50

读实验时先固定协议。论文使用 Texas Backbone 开源数据，含 2019 年每小时气象、日历与负荷，并把负荷映射到改造后的 IEEE 十四节点系统。六类气象量加星期和小时的正余弦，一共每节点十个特征，所以单样本输入是十四乘十，输出是十四节点负荷。正式论文附录明确写前百分之八十用于训练，后百分之二十用于测试；神经网络再把训练集前百分之三十作为预训练数据，其余作为敏感数据。训练使用一百轮、batch 十六、Adam、十的负四次方学习率和余弦调度，并记录早停最佳模型。此前复现分支的时间划分与原文相反，新版只报告原文，不把两套协议下的结果混为一谈。

带走：本页报告论文配置；不把此前复现分支的相反时间划分混入。

来源：原文 V-A、Appendix D，PDF pp.6、10；Table II–III 见 B6

20 / S19 线性模型中，完整遗忘可能使测试 Cost 明显上升

建议时间：17:50–18:42

来看第一张结果图，原文图四。横轴是删除比例，三个子图分别评价 MSE、MAPE 和 Cost。蓝色、红色、绿色对应剩余、删除和测试数据，虚线是原模型，实线是完整遗忘后的模型。作者验证了线性模型的更新参数与剩余集重训一致；但测试集三个指标在这组实验里随删除增加而恶化，剩余集则拟合得更好。正文举例说，删除百分之二十训练数据时，发电成本可以增加约百分之二十。这个例子说明完整性和任务性能可能发生冲突，而不能被扩大成任何数据、任何删除方式都会降低泛化的普遍结论。

带走：这是本文实验情境下的结果，不是“任何数据删除都会恶化性能”的普遍定理。

来源：原文 Fig.4、V-B1，PDF p.7 / 期刊 p.7184；数字转述正文，未从图重估

21 / S20 样本对 MSE 的影响，与它对运行 Cost 的影响并不一致

建议时间：18:42–19:34

图五是从样本影响分数的层面解释这个不一致。作者从剩余集中抽取一千条样本，使供给不足和过剩两类等量，再比较不同外层准则下的影响分数。这里每个点是一个训练样本的影响，不是某个温度特征，也不是测试样本的直接预测误差。MSE 与 MAPE 相关系数为零点八二九，MSE 与 Cost 只有零点零七三，MAPE 与 Cost 为负零点四八零。后者有负相关，因此也不能笼统说完全无关；准确结论是成本影响与统计影响并不保持相同方向和强度。它支持使用任务梯度重新判断剩余样本的补偿价值，但相关分析本身不提供因果证明。

带走：统计准则之间较一致，但不能直接代替成本导向的样本价值判断。

来源：原文 Fig.5、式 (23)–(24)、V-B2；抽取 1k 样本，供给不足 / 过剩各半

22 / S21 删除 25% 后，放宽重加权预算可改善对应的评价准则

建议时间：19:34–20:22

图六讨论的不是百分之二十，而是固定删除百分之二十五，再改变 L1 补偿预算。黑色和橙色分别是原始模型与完整遗忘模型。预算趋近于零时，样本权重接近 1，各方法回到完整遗忘。随着预算放宽，用哪个指标指导重加权，就更容易改善那个指标。在线性模型结果中，成本导向改善 Cost 的同时，MSE 和 MAPE 可能变差；统计准则之间则有一定互相带动。这与图五的样本影响关系一致。我们应把它理解成不同目标下的折中，而不是把 TAMU 宣布为所有预测指标的统一最优方法。

带走：TAMU 更直接控制 Cost；不应由此声称它在所有指标上都优于 PAMU。

来源：原文 Fig.6、V-B3，PDF p.8 / 期刊 p.7185；黑线原始，橙线完整遗忘

23 / S22 更低的运行 Cost，可能以偏离剩余集重训参数为代价

建议时间：20:22–21:10

图七把论文核心折中直接画出来。横轴是运行成本，纵轴是与剩余集重训模型的参数二范数距离。完整遗忘参照的距离为零；沿红色曲线向低成本移动时，参数差会增大。这里不能把纵轴

当成攻击成功率，更不能直接把某个距离转成隐私 epsilon。它只是论文选定的完整性代理。还要注意，偏离均匀重训并不自动等于重新使用被删除的记录，因为算法仍在剩余数据上重加权；但是否满足某个具体隐私删除定义，需要进一步明确训练算法和保证对象。论文的贡献是把这一取舍显式化，而不是证明低成本与严格隐私永远可以同时满足。

带走：参数距离是本文的完整性代理指标，不等价于差分隐私或认证删除保证。

来源：原文 Fig.7、V-B3，PDF p.8 / 期刊 p.7185

24 / S23 CNN 结果也显示成本补偿，但精确性范围仍是最后线性层

建议时间：21:10–22:15

神经网络部分用的是前面冻结核心、解析拟合最后线性层的结构。这里放大原图八中与 Cost 有关的右上和右下两幅，完整六子图保留在备份页，避免投影时所有坐标字太小。左图仍然区分剩余、删除和测试集，并用虚线、实线区分原始和遗忘后模型；右图用红色表示 MSE-PAMU、蓝色表示 MAPE-PAMU、绿色表示 TAMU。论文在 CNN 和 MLP-Mixer 上观察到统计指标和 Cost 可以同时改善，只是改善速度不同，作者将这种较弱冲突解释为神经网络预测更准确。这个解释是本文的实验观察，不是任何更准确模型都没有任务错位的保证；完整性结论也仍然只针对最后线性层。

带走：NN 中统计与成本的冲突较弱；作者将其解释为预测更准确，但不是普遍保证。

来源：原文 Fig.8 裁取右上 / 右下；V-C 与 Appendix E；完整 Fig.8–9 见 B1–B2

25 / X02 可以推进到特征分析，但“特征归因”不同于“特征遗忘”

建议时间：22:15–23:25

这里回应导师希望把样本推进到特征的想法。论文给每条训练记录一个权重和分数，没有直接给温度、风速等输入维度分数。一个自然扩展是固定模型，沿输入、特征提取器、线性头、两阶段运行到 Cost 的链路求导。预测归因是十四个输出对某个输入维度的导数，成本归因再接上下游 Cost 梯度。还可以对中间层的神经元或通道做归因，但隐藏特征不自动对应温度等语

义变量。这些是分析影响路径，不等于从训练中删除某种特征的影响。Captum 中的输入归因和层归因可作为工具选择，不能仅因为得到归因图就声称完成了机器遗忘或因果发现。

带走：原文按样本重加权；输入、隐藏表示和训练记录属于不同的分析对象。

来源：扩展方案，非原文实验；沿用原文式 (20) 的下游 Jacobian

26 / X03 先测输入响应，再研究训练样本中的某个特征如何影响 Cost

建议时间：23:25–24:30

建议先做最容易验收的实验：选定一个测试时刻和一个节点温度，按训练标准差的五个幅度扰动，保持真实负荷、模型权重和电网约束不变。先检查零扰动复现原预测与 Cost，再对比四个模型的响应。这个实验回答推理输入敏感性，不回答训练数据来源的因果影响。如果继续研究某条训练记录中的某个特征，可以对训练驻点条件求隐式导数，得到参数对该特征的变化，再乘 Cost 对参数的梯度。这需要可微损失、局部非奇异 Hessian 以及稳定的最优分支；若只拟合线性头，也要明确特征提取器固定。归因分数不满足守恒时，不能随意把一条样本分数硬拆成十份。相关气象量的独立扰动可能离开数据分布，后续需条件扰动、多时刻验证和独立测试集。

带走：可行性来自可微链路；局部性、特征相关性、秩与优化活跃集是主要边界。

来源：研究扩展与局部驻点隐式推导，非原文结果；σ 为对应训练特征标准差

27 / S24 论文把“移除影响”推进到“按运行任务补偿剩余数据”

建议时间：24:30–25:00

总结三句话。直接 MU 用剩余数据的梯度和曲率移除样本影响，在二次目标下可以与重训对应。PAMU 通过重加权剩余样本补偿统计性能。TAMU 进一步让两阶段电网运行成本的梯度指导这个补偿过程。连接两端的是样本梯度、训练曲率与任务梯度，而不是换一个更大的预测网络。读结论时保留三个边界：局部近似、最后线性层的精确性范围，以及参数距离和隐私保证的区别。最后，特征分析是可以继续推进的研究方向，但属于扩展，不是本论文已经完成的结论。先分析输入和层的响应，再研究训练记录中的特征影响，最后才讨论特征遗忘。

带走：最重要的连接：样本梯度 × 训练曲率修正 × 运行成本梯度。

来源：全文总结：式 (8)、(12)、(16)、(20)；边界与符号核对见备份

28 / B01 备份 B1｜CNN：保留原文六个子图的完整比较语境

建议时间：问答备份

原图八完整保留六子图。第一行依次是 MSE、MAPE 和 Cost，比较原模型与完整遗忘；第二行比较 MSE-PAMU、MAPE-PAMU 和 TAMU。主讲只放大 Cost 区域，这页用于检查其他指标与图例。不要用自己的复现数值替换这些论文曲线。

带走：完整性针对固定特征后的线性头；正文 V-C 报告 NN 上的指标冲突较弱。

来源：原文 Fig.8，PDF p.11 / 期刊 p.7188，未重画曲线

29 / B02 备份 B2｜MLP-Mixer：同样观察到重加权补偿效果

建议时间：问答备份

原图九提供 MLP-Mixer 的完整实验结果。与 CNN 类似，重加权可以改善对应指标，且统计与任务指标不像线性模型那样明显对立。这个结果支持方法不局限于线性输入预测器，但精确性仍依赖冻结核心和最后线性层的结构，而不是 MLP-Mixer 所有参数均能一步精确删除。

带走：图中结论限于作者的数据、模型与实验设置，不是跨数据集保证。

来源：原文 Fig.9，PDF p.11 / 期刊 p.7188，未重画曲线

30 / B03 备份 B3｜固定活跃集可仿射，不等于跨切换点处处可微

建议时间：问答备份

论文命题三的证明固定活跃约束，因而得到对应区域内的仿射表达。这个一维例子说明为什么需要限定区域：目标强凸，唯一不等式的梯度非零，所以在零点 LICQ 满足，但解是 max 零和 z，零点不可微。一般需要区分固定活跃集局部导数、几乎处处导数，以及切换点所用的广义

导数或数值处理。因此应把论文表述与这个边界并列说明，而不是删除原文命题，也不要把反例当成证明论文全部实验不可用。

带走：这是独立数学反例，不是作者实验；不能把命题 1/3 读成无条件全局光滑保证。

来源：对原文 Proposition 1、3 与 Appendix B 的条件辨析；反例为本汇报补充

31 / B04 备份 B4｜最后线性层的唯一解取决于特征矩阵的秩

建议时间：问答备份

附录 C 把多输出 MSE 写成分块二次型，X 满列秩使每个 X 转置 X 正定，因此目标有唯一最优解。对于带偏置的实现，常数列也应计入秩检查。重加权可能把一部分样本权重压到零，所以原始 X 满秩，并不能无条件推出加权后仍满秩。若出现退化，不能悄悄加岭正则再称目标没变，需要明确更改，并匹配相同的重训参照。

带走：“使用 Tanh”或“它是线性层”本身都不等于已验证 Hessian 可逆。

来源：原文 Proposition 2、式 (A.8)–(A.9)；加权秩条件为补充说明

32 / B05 备份 B5｜原文、算法重述与此前代码复现的四个口径区别

建议时间：问答备份

这页避免把论文与我们之前运行的代码口径混为一谈。成本在首阶段松弛为零时两种写法相等，但非零时不同。时间划分在正式论文和当前复现分支中方向相反。计算 m 时按式二十一保留负号。最后，论文用到 test 集指导权重，这个评价协议应与完全独立的泛化测试区分；参数二范数距离也不能自动对应隐私认证。所有这些核对都不改变原文图片，只用于清楚说明读者正在比较什么。

带走：本版原图与数字只来自上传论文；温度扰动等后续实验没有混入。

来源：原文式 (18)、(21)–(22)、Appendix D；代码比较为独立核对

33 / B06 备份 B6｜原文 CNN 与 MLP-Mixer 结构表

建议时间：问答备份

此页原样放置两张结构表，便于回答卷积核、步长、通道数与 Mixer 配置。表二记录卷积层八个滤波器、三乘三与四乘四核、相应 padding 和 stride，以及六十四维 Tanh 层与十四维无激活输出。表三给出两个 patch、两个 Mixer block、六十四维 MLP 及相应激活。不要把此前项目分析中的参数总数当作原文表格直接报告的数字。

带走：完整训练配置在 Appendix D；主讲不展开每个结构超参数。

来源：原文 Table II、Table III，PDF p.10 / 期刊 p.7187

34 / B07 备份 B7｜原文已核验，视频模板仍待可读取材料

建议时间：问答备份

本版已不再缺原论文：全部公式编号、九张原图、实验协议和正文数字均对照上传的 IEEE 正式版。用户提供的 B 站链接目前页面和接口都被网络代理拦截，无法观看，因此没有猜测视频的标题、布局或讲述方式。当前使用清晰的学术版式与此前 MIT 叙事原则，若之后提供视频或截图，可在不改变已核验论文内容的前提下重新匹配视觉模板。

带走：如需精确匹配视频版式，请提供视频或关键页截图；论文内容无需再等待。

来源：上传 PDF、MIT 官方课程页源码及 video_access.json；未运行新的电网实验