报告一 | Exact 遗忘：SISA 分组重训练

代表论文：Machine Unlearning。 Bourtoule 等，IEEE Symposium on Security and Privacy，2021；预印本发表于 2019 年。方法通常简称 SISA。

论文入口　正式出版 DOI　作者代码

先讲清楚这篇为什么值得读

普通模型把所有训练数据的影响混在同一组参数中。删除一条记录后，完整重训很昂贵。SISA 在最初训练时就划分数据、隔离子模型，并保存中间检查点，使删除请求只触发局部重训。

一句话：先把训练过程设计成可拆开的结构，将来删除数据时，只重做真正受影响的部分。

本次需求	本报告回答
exact unlearning，分组重训练	什么条件下局部重训与同流程重训等价
应用到电网	按训练样本分片，输出仍是完整的 14 节点负荷向量
与已有 CNN 联系	冻结核心 + 多个预测头的可行方案与保证范围
可展示成果	分片流程图、推导、代码定位、实验设计与数值校验

证据范围。 已读取作者 README、sisa.py、sharded.py、aggregation.py 等实现，并固定提交版本。当前 arXiv / IEEE 全文访问返回 403，未取得 SISA 论文全文。因此本文是“作者代码核对 + 独立数学说明”的文献研究报告，不声称逐页精读，也不引用未核实的原论文实验数字或章节编号。

本轮执行内容。 编写报告与教学数值校验；没有重新训练电网 CNN，没有生成新的电网 Cost 结果。电网迁移部分均为待实施方案。

1 | 先用综述建立机器遗忘的概念

建议先读 Nguyen 等的 A Survey of Machine Unlearning。作者仓库确认：2022 年预印本，2025 年发表于 ACM TIST，正式 DOI。再参考 Jiang 等的 Machine Unlearning: A Survey（ACM CSUR）。两者用于建立分类与阅读路线；本轮取得的是公开文献索引，未取得综述全文。X

引用量用于筛选，不用于证明算法正确。实时引文接口受限；附带说明保留可核对的第三方历史快照，明确平台声明、快照日期和未独立核验状态，不给出当前排名。注意同名综述有多篇，不能把 Xu 等的 arXiv:2306.03558 与 Jiang 等的 CSUR DOI 混为一篇。

令 D 是完整训练集，D_f 是要删除的数据，$D_r = D \setminus D_f$ 是剩余集。A 表示完整训练算法，包含数据处理、初始化、训练和输出规则；U 表示遗忘算法。

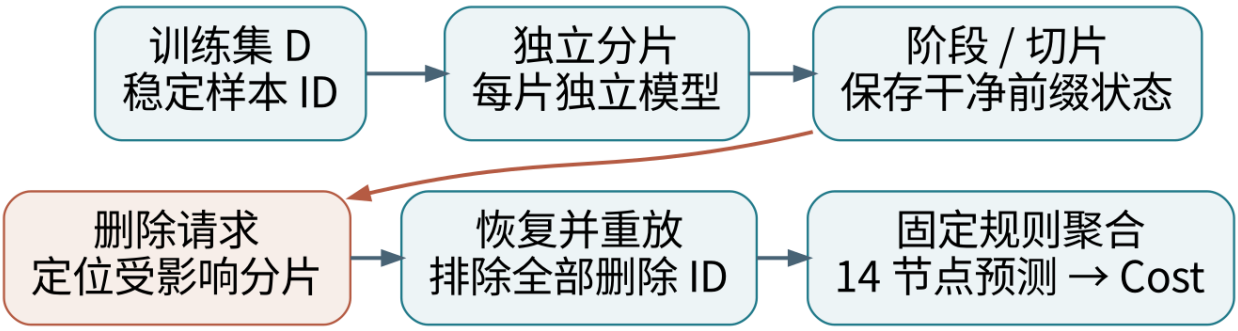
$$Law[U(A(D), D, D_f)] = Law[A(D_r)].$$

这是本报告采用的 exact 定义：删除后模型的分布，等于同一训练流程从未使用删除数据时的模型分布。若训练完全确定，可直接比较模型或完整状态。随机训练时，参数逐位相同并非分布等价的唯一表达。

概念	通俗解释	常见误解
Exact unlearning	与约定的重训流程等价	与任意一个单模型的重训结果相同
Approximate unlearning	在声明的误差或分布标准下接近重训	忘记集准确率下降就算成功
Certified removal	在假设下给出可证明的统计保证	参数差很小就自动得到认证
Retain utility	保留其余任务的可用性	测试 MSE 是唯一标准

遗忘的目标是接近“未看过这些数据”的模型。删除后仍能正确预测某个删除样本，可能来自剩余数据中的共同规律，不自动表示删除失败。

2 | SISA 的结构：分片、隔离、切片、聚合



SISA 分组重训练结构

Sharded（分片）： 把训练样本划为互不重叠的 S 份。每个分片训练一个模型。这里分的是样本，不是把 14 个输出节点分别交给 14 个模型。

Isolated（隔离）： 一个分片内的数据只影响该分片自己的训练状态。共享特征提取器如果使用了待删除数据，就会打破这种隔离；共享的全局标准化参数也需要纳入检查。

Sliced（切片）： 分片内部按固定顺序划成 R 个切片；在各阶段保存训练状态。作者实现逐步扩大已见前缀，并在阶段内使用该前缀训练，不是每阶段只用一个新切片。

Aggregated（聚合）： 汇总各子模型输出。作者代码针对分类做投票或概率聚合；迁移到负荷回归可以预先约定均值，但这是回归适配方案，需要重新验证。

$$\hat{y}(x)=\frac{1}{S}\sum_{s=1}^{S} f_{\theta_s}(x).$$

删除样本位于分片 2 的切片 3，就回到该分片切片 3 之前的干净状态，跳过删除记录，重放后续训练。其他分片保持原样。

3 | 为什么局部重训能够是 exact

以下是报告的独立说明；不冒充未读取全文中的定理编号。设分片划分规则固定，删除记录后不把剩余样本重新分片；各分片独立训练，聚合规则固定且不含未清除的删除数据影响。

$$D=\coprod_{s=1}^{S} D_s, D_{f,s}=D_f\cap D_s.$$

$$\theta_s^- = A_s\left(D_s\{D¿¿f,s\}\right), f^- = Agg\left(f_{\theta_1^-},\ldots,f_{\theta_S^-}\right).$$

若某分片没有删除记录，原状态就是该分片在剩余集上的训练结果。若受到影响，就从干净前缀恢复，按与参考重训相同的规则重放。于是每个分片都对应其“从未包含删除记录”的参考训练分布，固定聚合后的分布也相同。

删除算法的可执行逻辑

输入稳定样本 ID，列出所有受影响分片。

对每个受影响分片，找到最早包含删除记录的训练阶段。

找到该阶段之前没有使用任何删除记录的检查点；没有则从干净初始化开始。

恢复权重及所需训练状态，重放后续各阶段，所有数据读取都排除累计删除记录。

更新该分片预测；其他分片保持原状态，按同一规则聚合。

完整状态的重要性。 使用 Adam 时，动量和二阶矩也是训练记忆；调度器、BatchNorm 统计、随机数状态和数据顺序也可能影响重放。若省略它们，就不能仅凭“读取了同一权重检查点”声称精确恢复。

比较对象必须一致。 这里参考的是同一分片、阶段、随机机制下的训练流程；并不保证等于把所有剩余数据放进一个普通 CNN 训练得到的结果。

4 | 提速来自哪里，20% 删除时会怎样

一次只删除一条记录时，只需重训一个分片；干净检查点还能节省该分片的部分历史训练。但分片越多，每个模型可用样本越少，预测质量、存储和推理开销都可能变化。

若等大小分片、独立均匀抽取 k 次删除位置，受影响分片数的教学近似为：

$$E[S_{affected}] = S\left[1 - \left(1 - \frac{1}{S}\right)^{k}\right].$$

对有限数据中无放回删除 k 个样本，分片大小为 n_s 时，应使用：

$$E[S_{affected}] = \sum_{s=1}^{S}\left[1 - \frac{\binom{n - n_s}{k}}{\binom{n}{k}}\right].$$

你的既有设置是在 4906 个敏感样本中删除 981 个。若这些记录散布各片，极可能所有分片都需要重训，而且最早受影响切片可能很靠前。因此不能预先承诺“20% 遗忘就有 S 倍提速”。Helpful 选择不是均匀随机抽样，上式也不是该选择策略的直接保证。

要测量的成本	为什么必须测量
初始训练总时间与峰值显存	多模型和检查点带来额外开销
单次与累计删除耗时	删除批量与历史请求改变收益
重放阶段数、受影响分片数	解释提速或退化的原因
存储和推理时延	电网在线应用有实际资源限制
测试 MSE / MAPE / 调度 Cost	局部训练可能牺牲预测与运行经济性

时间比较需包括数据处理、恢复、重训和聚合。至少同时报告“同一 SISA 流程完整重训”和“普通单模型重训”，不要把两种参考混为一列。

5 | 作者代码定位与迁移前的核验

固定作者提交：50a3ada6c777f6882a1764d74a4978bfd61ec6f9。所有链接都固定到这个版本。

文件与位置	已核对的实际行为
sisa.py，约 107–192 行	计算切片大小、查找前缀缓存、恢复前一阶段、前缀累积训练
sharded.py，约 23–58 行	按排除删除 ID 后的前缀计算哈希，读取不含删除记录的 batch
sisa.py，约 216–263 行	恢复及阶段缓存保存 model.state_dict
aggregation.py	分类输出加权后 argmax；不能原样用于连续负荷回归

源码有 Adam 选项，但所见缓存只保存模型 state_dict，没有同时保存 Adam 状态。这是对该实现的检查点完整性观察，不代表论文主张已经被否定。迁移时应选择可一致重放的训练器，或完整持久化训练状态，并独立验证。

分片哈希是缓存索引，不是遗忘证书。它说明缓存使用了哪些样本 ID，不自动证明优化器、预处理、共享参数都不含删除信息。

与本项目的直接对应

utils/net.py 定义 CNN；func_operation.py 负责模型与数据构造；utils/funcs.py 有仿射头求解与评估；utils/optimization.py 是两阶段 Cost 路径。SISA 应作为独立训练与删除流程新增，不改写既有已验证结果。

本报告没有直接执行作者分类脚本；代码核对和下页的合成数值校验不是原论文实验复现。

6 | 如何迁移到 14 节点负荷预测

方案 A：整个 CNN 按样本分片。 每个子模型都接收 14×10 输入，预测 14 节点负荷。每片独立训练完整 CNN。保证范围清楚，但初始训练、存储、预测误差和推理开销均需实测。

方案 B：固定公共核心，敏感集预测头分片。 采用已有 64 维隐藏表示，每个分片训练 64→14 的头；聚合所有头的预测。该方案更接近当前冻结核心的项目结构。如果特征提取器和预处理确实不依赖删除数据，可讨论条件于这些固定组件的精确删除。

层或组件	建议处理	保证边界
Conv1 / Conv2 / lin1 / Tanh	方案 A 逐片训练；方案 B 固定	固定核心若见过删除数据，不能忽略
64→14 预测头	每分片独立训练与删除	精确性以该训练目标和流程为准
标准化、节点选择	明确是否依赖删除记录	数据影响也可能存在于非模型参数中
两阶段优化	保持原目标函数和系统约束	遗忘算法只改变预测输入

本项目额外要查的地方。 clean_data.py 用全年数据做气象标准化与节点选择；utils/dataset.py 用全年负荷最大值、均值和标准差进行缩放。因此即使核心只在 disjoint core 集训练，也不能据此直接声称“完整流程无删除数据影响”。需定义固定预处理条件下的保证，或重新设计仅依赖允许数据的预处理协议。

先聚合预测，再运行两阶段优化：

$$C\left(\frac{1}{S}\sum_{s}\hat{y}_s, y\right) \neq \frac{1}{S}\sum_{s} C\left(\hat{y}_s, y\right) \text{一般不成立相等关系.}$$

真实负荷、线路和机组约束保持不变。不能把各子模型 Cost 的平均值当作集成预测的调度 Cost。

7 | 待实施的电网对照实验

以下是研究设计，不是已完成结果。沿用 TX-123BT / case14 与既有 20% 删除 ID，先验证小规模，再扩展。新增随机删除和明确的数据污染删除场景，避免结论只依赖 helpful 排序。

项目	固定规则或对照
模型	普通单 CNN；SISA 完整 CNN；可选冻结核心多头
分片和切片	先试 S=5、R=5；这是起始设计，不是论文推荐最优值
删除规模	1 条、1%、5%、20%；共享同一删除集合
随机性	种子 42 做调试；正式扩展多个种子
参考重训	同一分片流程从干净初始化重训全部剩余数据
预测评价	测试 MSE、MAPE、与参考预测的逐节点差
下游评价	cost1、cost2、总 Cost、约束残差、求解状态
效率	初训、恢复、删除、累计删除、存储和推理开销

验收顺序。 先确认空删除不改变模型；再确认单条删除只触发其所属分片；对受影响片比较恢复重放和干净重训。训练完全确定时检查完整状态与预测；随机训练则说明随机机制，并用多个独立运行评价分布，不能用一次近似相等代替分布证明。

电网适用场景。 某批仪表记录被确认错误；某个用户撤回数据授权；某段攻击数据需要删除。这些是不同删除语义，应分别确定删除单位。当前 14 节点合成负荷数据不能直接支撑用户隐私合规结论。

避免原有评估泄漏。 已有 helpful 选择用到了评估信息；新算法调参和选择分片规模应使用独立验证集，最终测试集只用于最后报告。

8 | 本轮实际数值校验：精确性究竟指什么

为了让推导可核对，新增 experiments/verify_unlearning_reports.py，使用明确标注的合成数组。SISA 示例是 24 样本、3 个分片、每片 4 个切片的确定性岭回归；检查点用充分统计量保存。这不是作者神经网络实现，也不是 TX-123BT 结果。

教学检查	实际结果
从干净前缀恢复并删除索引 3、6（从 0 计）	只影响 3 个分片中的 1 个
恢复重放 vs 同流程分片重训	参数最大差约 2.44×10^{-15}
未受影响的两个分片	参数逐位相同
分片均值集成 vs 全数据单模型重训	最大预测差约 0.370189

第一项支持“隔离正确时可局部重做”；最后一项说明“与同分片流程等价”不意味着“与任意普通模型相同”。浮点小误差只是这个确定性例子的数值误差，不构成一般神经网络 exact 保证。

复算命令（仓库根目录）：

python experiments/verify_unlearning_reports.py

该命令同时执行三份报告的 14 项教学检查，结果保存于 reports/unlearning_three_methods/numerical_checks.json。全套 14 项通过，0 项失败；不是新增的电网复现实验通过数。

预期可向导师提出的问题：对于电网记录删除，分片隔离的效率收益能否抵消模型集成带来的预测和调度成本损失？答案需要下一轮实测，不由这组教学数组决定。

9 | 组会讲法、结论与参考链接

两分钟讲法。 我先用综述区分了精确遗忘和近似遗忘。精确遗忘以“同一流程在剩余数据上重训”为参照。SISA 在初始训练时把数据分片并隔离模型，分片内部保存阶段状态；删除时从最早受影响阶段之前恢复，只重训后续部分。

对本项目，可以比较整 CNN 分片与固定核心、多头分片。但已有核心和缩放参数的来源必须审计。20% 删除可能遍及所有分片，不能预先承诺大幅提速。最终仍需把集成后的 14 节点预测送入同一个两阶段优化程序，评价 Cost。

本篇结论

SISA 最值得借用的是“提前组织训练依赖，控制删除时需要重做的范围”。它提供结构化重训路线，不能直接安装到一个早已训练好的普通 CNN 上就获得完整 SISA 能力。当前只完成阅读材料、源码核对和数学教学校验，正式电网对照尚未执行。

阅读与核对链接

Bourtoule et al., Machine Unlearning，论文入口 X

正式发表版本，IEEE S&P 2021X

作者代码，固定版本 X

Nguyen 等，A Survey of Machine UnlearningX

该综述作者维护的分类与文献索引 X

Jiang 等，Machine Unlearning: A Survey，CSURX

Guo 等，Certified Data Removal，作为近似路线对照 X

Foster 等，SSD，作为参数修改路线对照 X

版本、访问状态和文件哈希见同目录 source_manifest.json。日期：2026-10-22（北京时间）。