报告三 | 持续学习启发的近似遗忘：SSD 与模型分层

代表论文：Fast Machine Unlearning without Retraining through Selective Synaptic Dampening。 Jack Foster、Stefan Schoepf、Alexandra Brintrup，AAAI 2024，38(11)：12043–12051。

论文入口　正式发表 DOI　作者代码

一句话：借用持续学习中“判断哪些参数重要”的思路，找出特别依赖删除数据的参数，再选择性削弱它们。

为什么选它作为第三条路线

你的重点是 approximate unlearning、持续学习和模型分层。SSD 在参数重要性上与持续学习直接衔接；作者 ssd.py 明确注明重要性计算改编自 Avalanche 持续学习库。它也适合讨论先改预测头、再改高层模块，而非人工逐个寻找“某个数据对应的唯一权重”。

术语边界。 这里选择的是“持续学习启发的近似遗忘”，SSD 本身不是完整的多任务持续学习训练流程；重要性估计来自该方向，并不意味着 EWC 正则项就是 SSD 删除算法。若导师要求严格的流式持续学习任务协议，还需补充任务序列和对应基线。

证据范围。 已读取作者 README、核心 ssd.py、策略入口并固定提交。arXiv / AAAI 全文访问返回 403，未取得全文；因此本报告的公式与流程以作者代码为依据，持续学习解释和电网迁移属于独立分析，不提供未核实的原论文实验数值。

本轮不重新训练、不修改已有 CNN 权重、不产生新的电网 Cost 结果；完成的是报告和数学教学校验。

1 | 持续学习的“保留”怎样联系到“遗忘”

持续学习关心模型学新任务时如何保留旧能力。机器遗忘则要求移除指定数据影响，同时保留其余能力。两者都涉及：哪些参数承载哪些信息，修改它们会伤及多少其他任务。

建议铺垫：Overcoming catastrophic forgetting in neural networks（EWC）。下式是对 EWC 思路的教学表达，不是 SSD 的目标函数：

$$L_{new}(\theta)+\frac{\beta}{2}\sum_j F_j\left(\theta_j-\theta_j^{old}\right)^2.$$

F_j 描述旧任务对第 j 个参数的敏感程度。重要参数动得越多，代价越大，所以倾向于保留。β 控制保留强度。

SSD 借用“参数重要性”这个工具，却用它回答不同的问题：一个参数是否对删除集特别重要，相对于整个训练集又有多突出？如果突出，就考虑衰减该参数。

方法	重要性在做什么
EWC 的教学理解	保护旧任务重要参数，减少灾难性遗忘
SSD	识别偏向删除集的参数，并进行选择性衰减
本项目层分析	记录激活、输出归因、内部消融；用途不同于删除集重要性

一个通道对某次预测贡献大，并不表示它只记住了删除样本。Captum 归因不能直接替代 SSD 的删除集梯度统计。

综述入口：Nguyen 等、Jiang 等 CSUR。两篇全文本轮未取得，本文只用公开索引建立阅读路线。

2 | SSD 的核心：选择参数，再衰减参数

先用梯度平方估计参数在数据集合 S 上的重要性。理想的逐样本统计可写为：

$$I_S(j)=\frac{1}{|S|}\sum_{i\in S}\left(\frac{\partial \ell_i(\theta)}{\partial \theta_j}\right)^2.$$

原实现使用 batch 平均损失梯度的平方，再对 batch 求平均，区别见下一页。令 I_D 是完整训练集重要性，I_f 是删除集重要性，α 是选择阈值。

$$J=\{j: I_f(j)>\alpha I_D(j)\}.$$

这些位置对删除集“相对更突出”。作者默认 exponent=1、裁剪上界=1 时，所选参数乘上：

$$s_j=min\left(1,\lambda_{SSD}\frac{I_D(j)}{I_f(j)}\right), j\in J.$$

$\theta_j^- = s_j\theta_j (j\in J).$

$\theta_j^- = \theta_j (j\notin J).$

α 控制选哪些参数；λ_{SSD} 控制衰减幅度，不是前一报告的 L2 正则系数。代码还提供 exponent 等设置，以上只对应所见默认策略，不混用其他 SSD 变体。

完整集重要性可提前缓存；删除时计算删除集重要性，再做逐坐标乘法。提前缓存本身也有成本，不能将总成本写成“只访问删除集”。

该方法不把参数更新到剩余集最优解，也不自动保证与重训分布接近。它是需要经验验证的近似删除。

3 | 作者实现的细节会怎样影响结果

固定提交：cdfdc0e35c1908e032a6e150d882b0fa17833f85。

作者代码位置	实际行为
ssd.py：calc_importance	CrossEntropyLoss；每个 batch 反传后累积 $p.grad^2$，再除以 batch 数
ssd.py：modify_weight	按删除 / 全集重要性比较，选择位置并乘衰减系数
forget_random_strategies.py：ssd_tuning	model.eval()；依次统计删除集、全集重要性并修改权重

最容易忽略的统计差异：

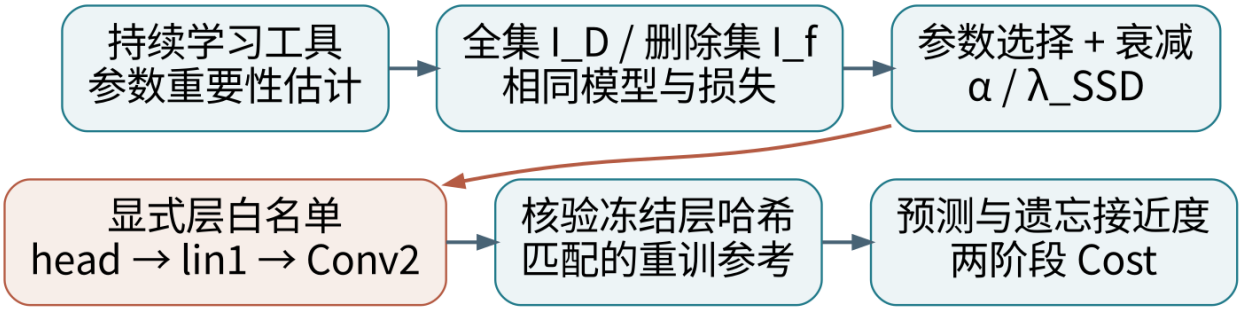
$$\left(\frac{1}{B}\sum_i g_i\right)^2 \neq \frac{1}{B}\sum_i g_i^2.$$

两个样本的梯度为 +1、−1 时，左边为 0，右边为 1。batch 划分、样本排列和最后一个 batch 的大小都能影响统计。若迁移时改成逐样本梯度，必须记录为估计器变化，并与原 batch 版本做对照。

分层限制不能只看参数名字。 类初始化读取了 min_layer、max_layer 等字段，但所见 modify_weight 循环没有用这些字段过滤层。因此把两个值设置好，并不意味着实际只改指定层。迁移时应显式传入参数名白名单，并检查未开放层的哈希完全不变。

原数据循环解包 x, _, y，损失是分类交叉熵。本项目数据格式和 14 维连续目标不同，不能不经适配直接调用。报告没有执行原图像分类基准。

4 | 用模型分层控制遗忘范围



持续学习启发的 SSD 与 CNN 分层方案

当前已有模型的可学习模块为 Conv1、Conv2、lin1 和 64→14 预测头；ReLU、Flatten、Tanh 在这里没有独立可训练权重。模型内部激活和贡献已在此前报告中分析，本轮沿用其结构记录。

迁移阶段	开放的参数	能回答什么
L0：head-only	预测头的 910 个参数	是否可与已有直接遗忘 / 重拟合 / TAMU 比较
L1：head + lin1	再开放高层特征融合	高层表示改变是否改善删除与保留折中
L2：再开放 Conv2	加入较深卷积通道	是否需要修改局部组合特征
L3：全模型	所有 20006 个参数	全网干预收益能否抵消保留能力损伤

这是一组待验证的分层方案，不是 SSD 原论文已经证明的推荐顺序。每层都应单独选择验证集超参数，并与相同训练范围的剩余集重训基线比较。

单个参数会同时影响多个样本和多个节点。分层、通道或参数组更便于控制实验规模，但不能据此宣称某层独占“温度知识”或“删除样本记忆”。

如果开放原来冻结的核心，原有 head-only 重拟合不再是匹配的重训参考。必须先定义新的训练算法，不能沿用旧标签后直接横向排名。

5 | 从图像分类适配到负荷回归

当前任务输出 14 个连续负荷，不使用分类交叉熵。一个清楚的迁移起点是：在现有标准化输出空间，采用与既有训练相同的 MSE，计算梯度重要性。

$$\ell_i = \frac{1}{14}\sum_{b=1}^{14}\left(\hat{y}_{i,b} - y_{i,b}\right)^2.$$

这是本项目适配方案。若用高斯观测模型解释 Fisher，应明确噪声方差与似然；在未推导概率模型前，应称为“梯度平方重要性”，不要直接宣称就是严格 Fisher 信息。

选择	实际影响与记录要求
标准化空间 MSE	各节点尺度按原训练协议处理
MW 空间 MSE	大负荷节点可能占更大比重；目标已改变
每样本 vs batch 统计	重要性估计不同，必须区分
完整集 vs 保留集作分母	原 SSD 使用完整集；换成保留集是变体
用 Cost 梯度选参数	属于任务感知新变体，应另列实验，不冒充原 SSD

第一轮建议保持原 MSE 训练约定，只改变参数选择和衰减机制，随后用固定两阶段优化独立评价 Cost。先建立一个可解释、可复算的基线，再讨论 Cost-aware 分层选择。

数值处理也要写清：只有选中且分母为正的位置才计算比例；$I_D = I_f = 0$ 的位置不选；$I_D = 0, I_f > 0$ 时按默认规则可衰减为零。若添加 epsilon 稳定项，其大小与影响必须记录。

乘法衰减不能把原本为零的参数更新成非零，也不一定向剩余集最优解移动。这是它与 Newton 更新的重要区别。

6 | 电网实验怎样设计才公平

固定 TX-123BT / case14、已有 CNN、删除比例 20% 和相同删除 ID。第一阶段只做 head-only SSD；参数选择使用验证集，不根据最终测试 Cost 调参。

对照方法	用途
原始模型、no-op	基准与空删除一致性
剩余集直接重拟合头	head-only 任务的参考重训
现有直接遗忘	与影响函数路线比较
SSD-head	持续学习启发的参数重要性路线
TAMU	下游成本导向重加权对照；不自动拥有同一删除保证

建议初步网格 $\alpha \in \{1,5,10\}$，$\lambda_{SSD} \in \{0.1,1\}$。这是待验证的起始设置，不是原文最优超参数；如没有参数被选中，要报告 no-op，不能当作遗忘成功。

需要同时报告：与参考预测的差异；保留集和独立测试 MSE / MAPE；cost1 / cost2 / 总 Cost；求解状态和约束残差；被选参数比例、每层改动比例、未开放层哈希；全集重要性预计算、删除统计与更新总耗时。

如评估成员推断，攻击应区分成员和非成员、按日期或负荷条件匹配并报告与重训的差异。单个攻击接近随机，只能说明该攻击未发现泄漏，不能替代认证。

沿用五档温度扰动检查模型响应，并扩展多个日期、负荷区间和种子。比较成本曲线的同时保留预测误差、保留能力与遗忘接近度，不能把“对温度反应更平”直接解释为更好。

以上均为后续实施计划，本轮未产生 SSD 电网结果。

7 | 本轮实际教学检查：规则是否按预期工作

合成例子中，五个参数的原值为 [2, −3, 0.5, 4, 7]；全集重要性为 [1, 4, 0, 2, 0]，删除集重要性为 [10, 1, 5, 0, 0]。设 $\alpha = 2$、$\lambda_{SSD} = 1$。

参数位置	是否选中	乘数	更新后
1	是	0.1	0.2
2	否	1	−3
3	是	0	0
4	否	1	4
5	否，两个重要性均为零	1	7

显式增加层白名单后，若前两个参数属于冻结核心，则它们保持 [2,−3]；这检验的是分层过滤逻辑，不是原代码已有的层限制功能。

另外两个检查：逐样本梯度 [+1,−1] 的平均平方为 1，但 batch 平均梯度的平方为 0；EWC 二次教学问题中，重要性为 [100,1] 时，对旧参数的保护强度不同，解约为 [0.990099,0.5]。

复算：python experiments/verify_unlearning_reports.py。这些是对源码默认公式的独立 NumPy 实现与数学校验，不是对原 SSD 程序的端到端执行，不证明其遗忘质量，也不是原论文结果。

全部三篇报告共 14 项教学检查通过，0 项失败；记录见 numerical_checks.json。

8 | 局限、潜在创新与研究边界

参数重要性不等于独占记忆。 同一参数可能同时服务删除集与保留集；衰减可能损伤正常负荷预测。对角统计忽略参数间相关性，对参数重标定也敏感。

输出贡献不等于训练记忆。 一个隐藏单元对节点 4 贡献大，不等于它主要承载删除数据。已有内部消融图可以帮助定位干预后哪里改变，但不能当成删除证书。

多次删除会改变重要性。 在旧参数上计算的完整集缓存可能逐渐失效。连续删除协议需要说明何时重新估计、何时回到重训，不能无限复用首轮统计。

Cost 改善不保证遗忘更好。 SSD 可能降低保留能力，TAMU 可能改善经济性，但二者均需单独对照重训参考。电网中的约束活跃变化也使参数衰减与成本之间不呈简单线性关系。

可以形成的研究问题

“在相同删除集和保留能力约束下，按层限制的梯度重要性遗忘，能否比全参数衰减更接近参考重训，并减少电网运行成本波动？”

一个可能的新方向是把保留集重要性和 Cost 敏感性共同用于层或通道选择。但这是研究设想，必须与原 SSD、随机层选择、只改头和匹配重训进行消融，不能作为已有论文结论。

当前最合理的实施顺序

先完成 head-only SSD 与现有四模型的匹配比较；验证统计、参数白名单和独立评估均正确后，再开放 lin1 或 Conv2。若明确目标是用户隐私删除，应先处理核心和预处理对删除记录的依赖范围。

9 | 组会讲法、结论与阅读链接

两分钟讲法。 持续学习为了防止模型忘掉旧任务，会估计哪些参数重要。SSD 借用这个工具，把删除集与完整集的重要性进行比较，找出对删除数据特别敏感的参数，然后乘一个不大于 1 的系数。

对我的 CNN，可以先只开放 64→14 预测头，保留卷积核心，再逐步开放 lin1、Conv2；但每次都要有匹配的剩余集重训参考。原源码并没有自动执行字段中写出的层过滤，因此需要显式参数白名单和哈希核验。

本篇结论。 这条路线的价值是低成本的参数选择和分层干预；局限是不能自动保证删除、保持精度或降低 Cost。应把它作为新的经验基线，通过预测、遗忘接近度和两阶段运行成本共同评价。

论文与铺垫链接

Foster 等，SSD 论文入口 X

AAAI 正式发表页面 X

作者代码，固定版本 X

Kirkpatrick 等，EWC：Overcoming catastrophic forgettingX

Avalanche 持续学习库 X

Nguyen 等，机器遗忘综述 X

Jiang 等，CSUR 综述 X

Shibata 等，Learning with Selective Forgetting，IJCAI 2021X

Guo 等，认证删除，作为保证边界对照 X

第 8 项是进一步研究持续学习与选择性遗忘结合的阅读入口，本轮未读全文。SSD 全文受限，本文依据作者实现；不声称完成其论文全部实证结论的复核。日期：2026-10-22（北京时间）。