CNN 各层怎样形成最终预测

分析对象：原 Task-Aware 项目的已有 CNN 与四种敏感集预测头。分析重点是模型内部各层的表示、梯度贡献和内部消融，不是再次改变温度等原始输入。日期：2026-10-21。

Captum 是归因分析工具库，本身没有唯一神经网络结构。用户上传的 captum-master.zip 超过当前工具 32 MiB 读取上限，未能读取；本轮使用官方 Captum v0.7.0 源码，与既有 PyTorch 2.0.1 兼容，不声称等同上传包版本。

分析项	实际执行
固定样本	既有 test index 0，原始未扰动输入
模型	原始、20%直接遗忘、剩余集重拟合头、TAMU
层记录	8 个实际运算阶段；两次 ReLU 分别记录
层归因	Captum LayerActivation、LayerGradientXActivation
内部干预	ReLU1 的 8 通道、ReLU2 的 8 通道、Tanh 的 64 神经元逐个置零
规模	4 模型×80 次=320 次内部消融，记录 4480 个输出变化
验收	90 项内部一致性检查通过，0 失败

核心发现：四模型的核心激活逐位相同，贡献会因预测头参数改变而不同；原始模型节点 4 的最大绝对隐藏贡献来自神经元 9，直接遗忘/重拟合/TAMU 则来自神经元 26。该观察仅适用于当前固定样本。

1 模型内部的实际调用链

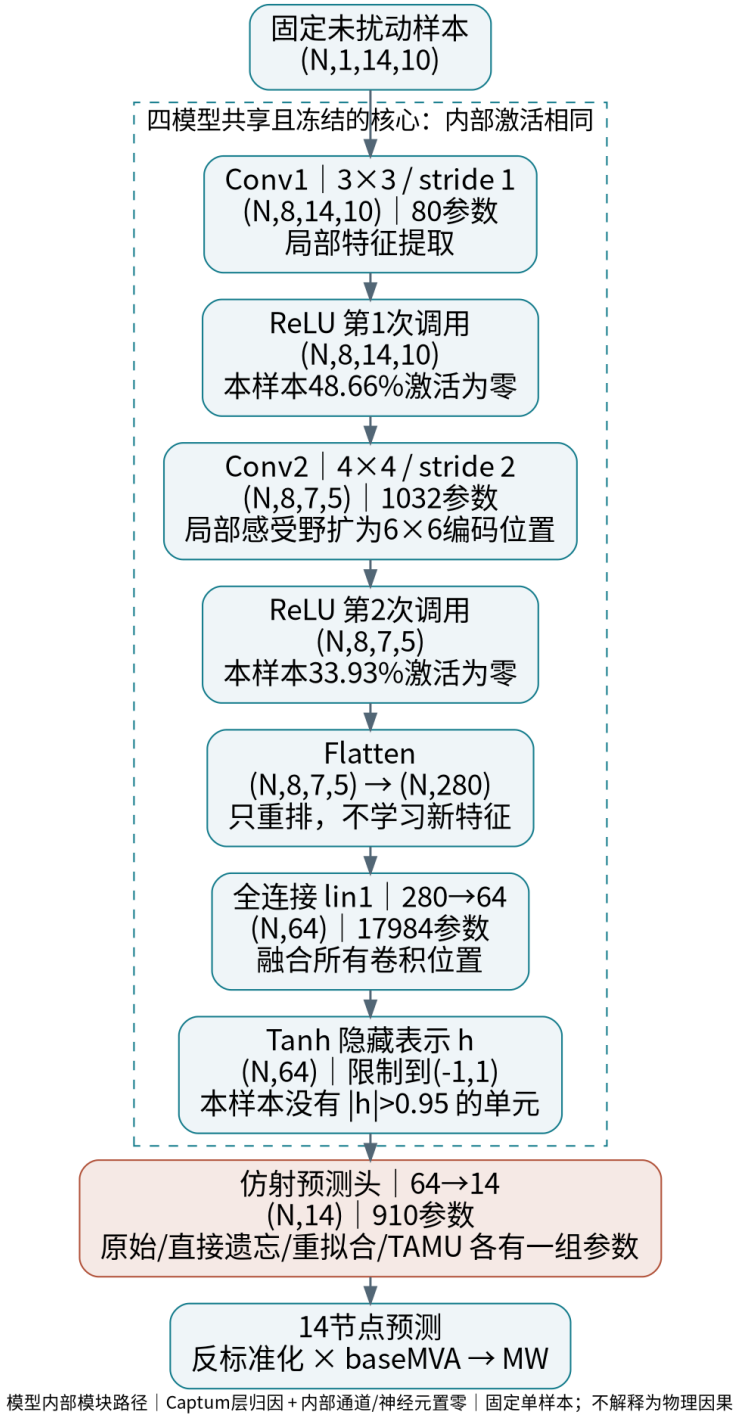


图 1 冻结核心与可更新预测头；图中 N 为批大小，本次 N=1。

原代码同一个 relu 模块调用两次；分析包装器将两次调用分成唯一命名 relu1/relu2，保持计算与预测逐位一致，避免层 hook 混淆。

2 每层做什么、形状怎样变化

阶段	实际输出形状	参数数
conv1	1x8x14x10	80
relu1	1x8x14x10	0
conv2	1x8x7x5	1032
relu2	1x8x7x5	0
flatten	1x280	0
lin1	1x64	17984
tanh	1x64	0
head	1x14	910

Conv1 在编码张量的局部 3×3 邻域提取 8 种响应；Conv2 组合已有通道并以步长 2 缩小空间尺寸，局部感受野约 6×6 编码位置。这里的相邻位置由 bus/特征排列决定，不能直接称为电网物理相邻。

ReLU 只保留正响应。Flatten 仅将 8×7×5 重排为 280 维；lin1 把所有位置融合到 64 维；Tanh 将表示限制到(-1,1)，可能因饱和而减弱梯度；当前样本没有绝对值大于 0.95 的 Tanh 单元。

最终预测头以 Wx+b 将 64 维隐藏表示读为 14 个负荷输出，再反标准化为 p.u.并换算 MW。实际有效网络共 20006 参数，其中预测头 910 参数。本轮没有重新训练这些参数。

3 看见各卷积通道的激活

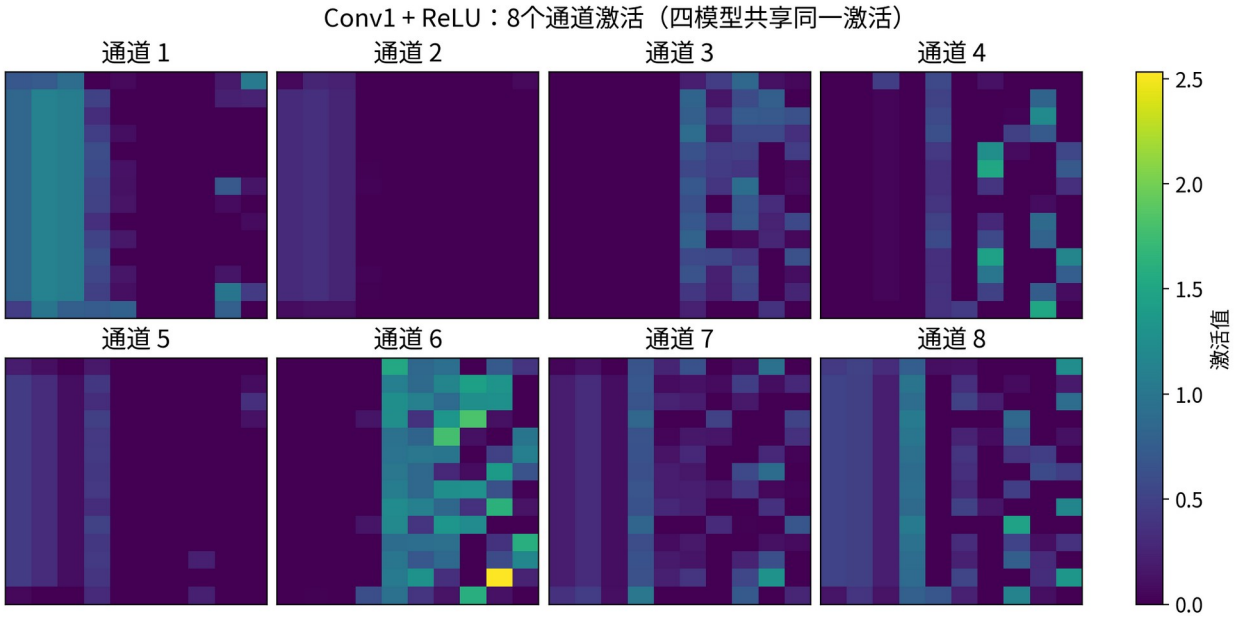


图 2 第一层卷积经 ReLU 后的 8 个通道；行列对应编码位置。

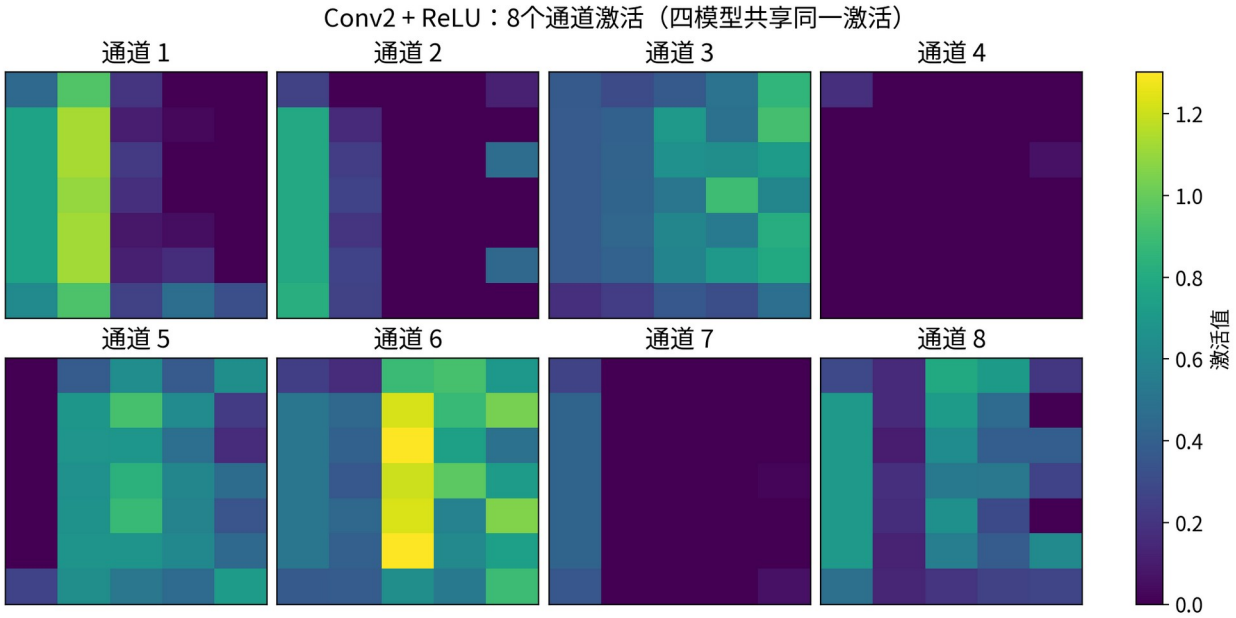


图 3 第二层卷积经 ReLU 后的 8 个通道。

当前样本 ReLU1 零激活比例 48.6607%，ReLU2 为 33.9286%。这描述哪些内部响应被门控，不表示通道已经学到某个已知物理含义。四模型核心相同，所以这些激活也相同。

4 哪些隐藏神经元在支持各输出

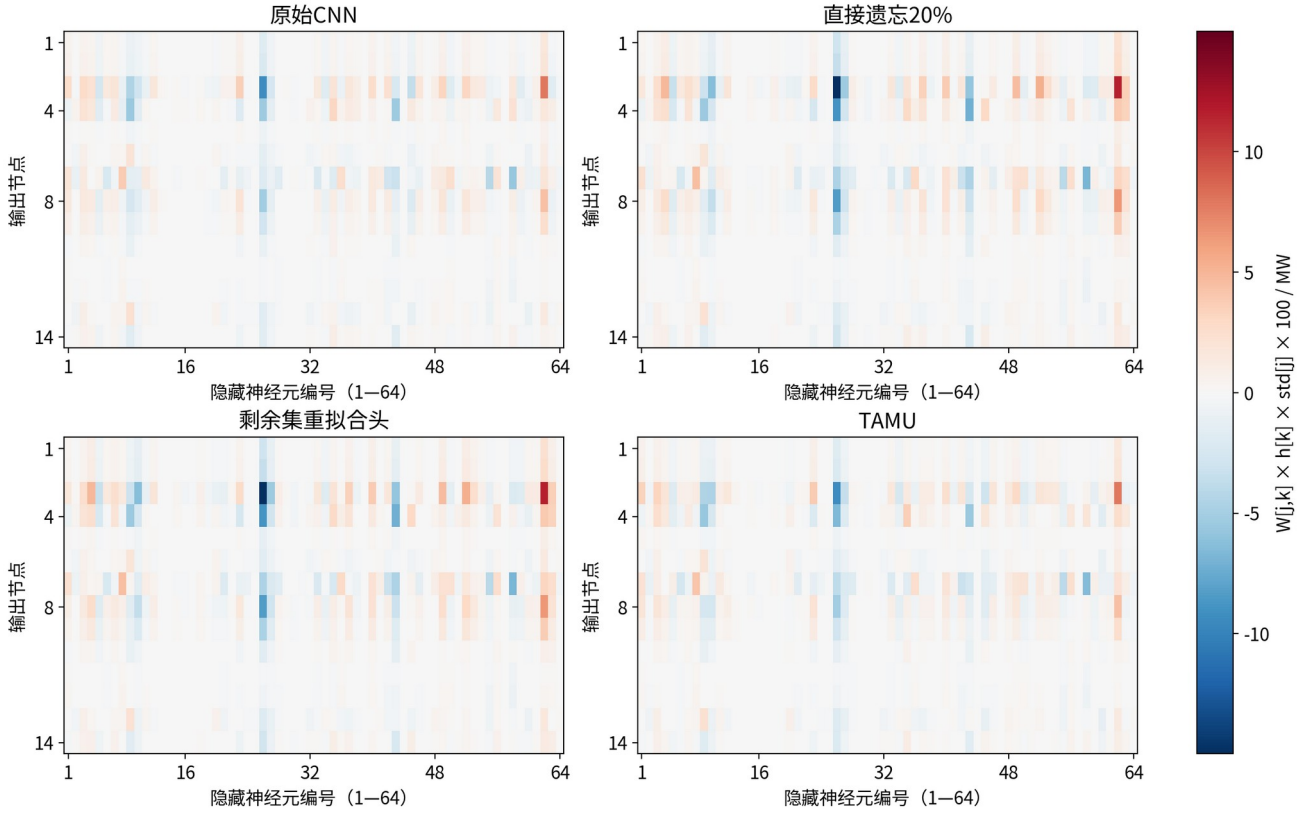


图 4 四模型的 64 隐藏神经元→14 输出贡献，单位 MW。

Captum 的 LayerGradientXActivation 计算“该层激活×目标输出对该层激活的梯度”。这里目标是每个节点的原始负荷预测（MW），不是 Cost。不同层的分数是同一预测的不同切面，不能相加或据其总量给层做全局重要性排名。

对最后仿射头，隐藏贡献具有精确表达：贡献[j,k]=W[j,k]×h[k]×std[j]×100。所有隐藏贡献加上(b[j]×std[j]+mean[j])×100，恢复节点预测。当前最大重构误差为 1.43e−14 MW。

这是对隐藏状态置零参考下的仿射读出分解；常数偏置单列。前面非线性层的 Gradient×Activation 一般只是局部归因，不自动具备同样的精确可加性。

5 节点 4：遗忘前后读出了什么

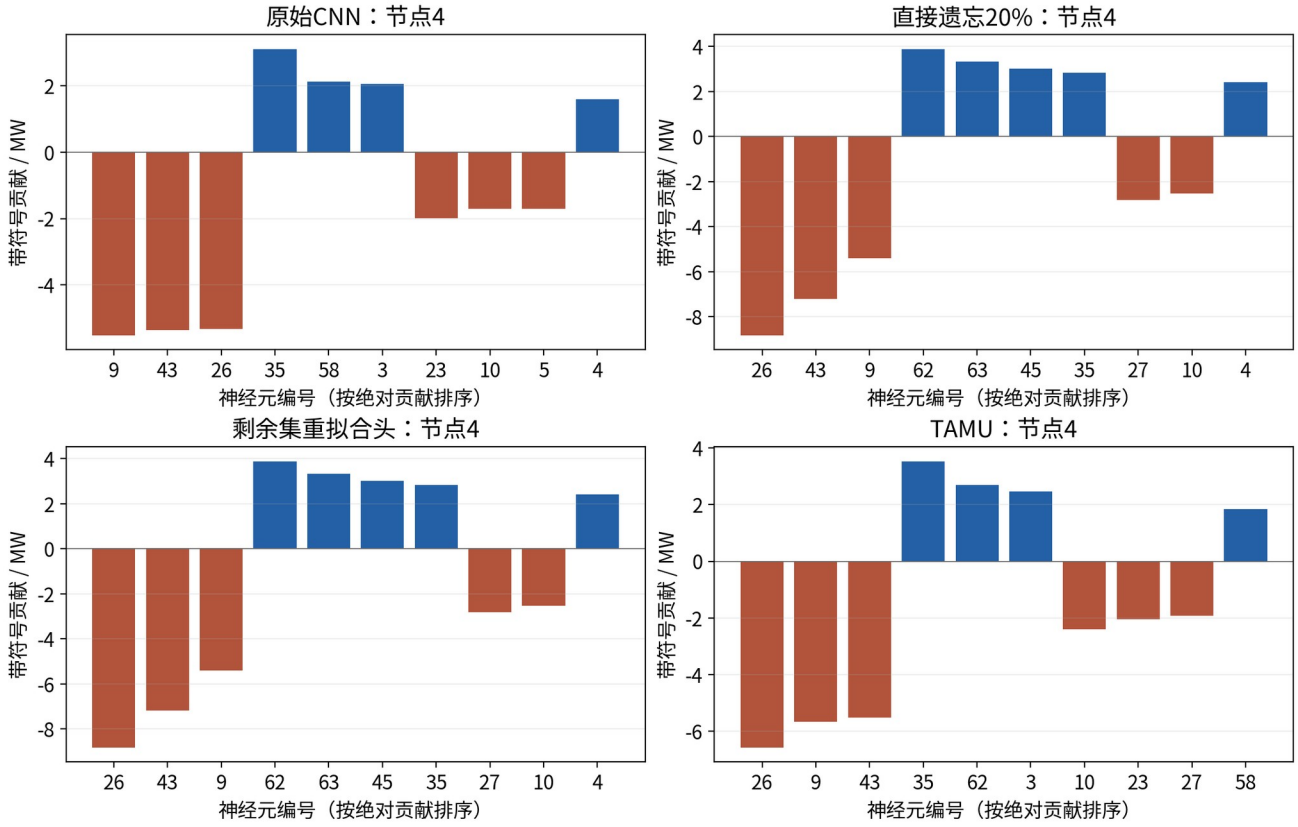


图 5 节点 4 的前 10 个绝对隐藏贡献；符号表示抬高或拉低该预测。

模型	节点 4 预测/MW	最大绝对贡献神经元	带符号贡献/MW
原始 CNN	51.640998	9	-5.526458
直接遗忘 20%	52.816433	26	-8.827747
剩余集重拟合头	52.816477	26	-8.827731
TAMU	51.204608	26	-6.576171

原始模型神经元 9 贡献−5.526458 MW；直接遗忘与重拟合的最大贡献转为神经元 26，约−8.8277 MW；TAMU 同为神经元 26，约−6.576171 MW。前层激活没变，改变的是预测头对同一隐藏表示的读出。不能据此称核心学会了新的特征，也不能把神经元 9 直接命名为温度神经元。

6 内部消融验证与结论范围

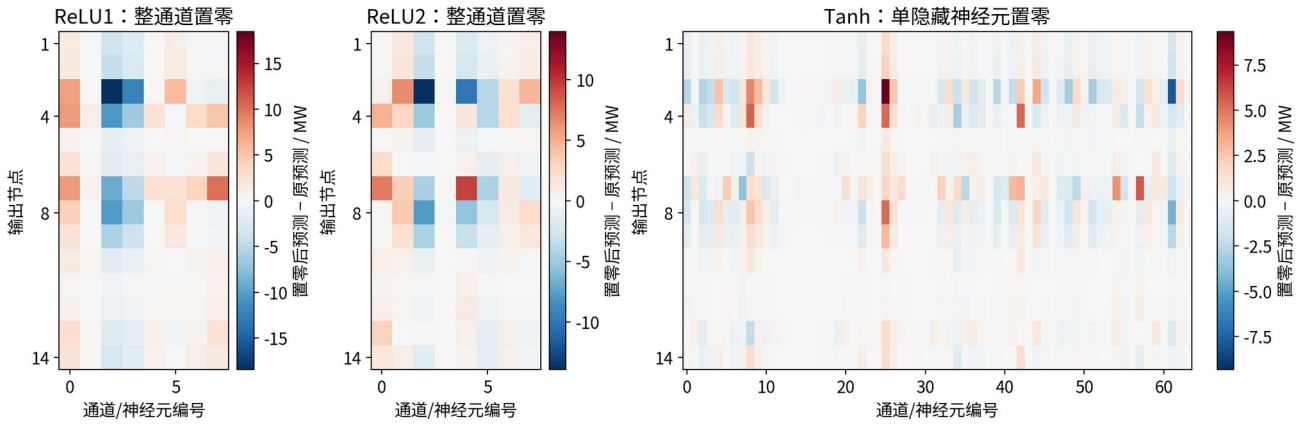


图 6 原始模型内部通道/神经元置零后，14 个预测怎样变化；各面板色标独立。

保持原始输入不变，将某个 ReLU 后的整通道或某个 Tanh 神经元激活置 0，再计算后续层。整通道包含许多空间位置，与单个隐藏神经元不是同样大小的干预，不能直接将两类峰值当作公平层排名。

原始模型将神经元 9 置零，节点 4 预测从 51.640998 增加到 57.167456 MW，增加 5.526458 MW，与其负贡献被移除一致。全部隐藏神经元置零检查的最大误差约 3.27e−14 MW。前层通道消融可能改变后续 ReLU 门控，未必等于局部 Gradient×Activation。

Captum 激活与手动记录完全一致；Captum 梯度×激活与直接自动微分完全一致；四模型预测与既有零扰动记录一致；模型参数与源快照均未变化。90 项检查为本轮内部一致性验收，不与此前实验测试数累加。

局限：仅一条固定样本；置零后的隐藏状态未必来自真实输入；归因依赖目标和方法；没有枚举完整的最重要神经元连通路径，没有宣称物理因果或全局层重要性。本轮不重新计算 Cost，也没有把数据输入扰动冒充模型层分析。

复现：使用 Captum v0.7.0，运行 experiments/analyze_cnn_layers.py；源码来源 https://github.com/pytorch/captum/tree/v0.7.0 。逐层数组、归因表、消融表及校验记录保存在本目录。